

説明可能 AI のための対比因子ラベル生成手法に関する研究

清野駿（筑波大学大学院 修士 2 年）

背景と目的

なぜ XAI(説明可能 AI) の重要性が高まっているのか？

- AI の社会実装が進む中で、「なぜその判断なのか？」という疑問が増加
- 医療・法務・教育など、**説明責任**が求められる分野で利用拡大
- LLM のようなブラックボックスモデルの普及により、透明性の欠如が顕著に

現在の課題は何か？

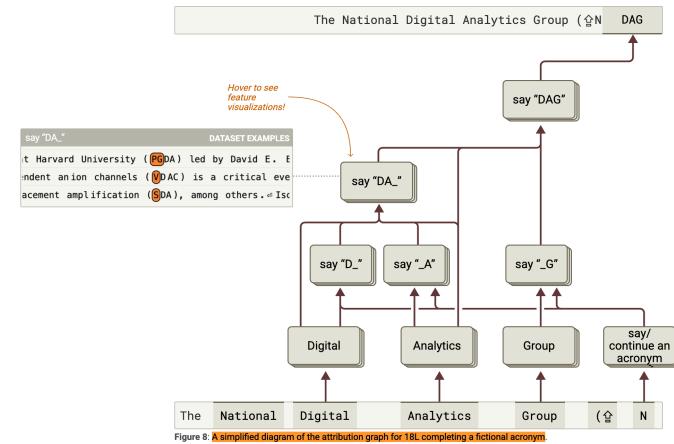
- 多くの AI モデルは「正答を出す」が、**理由は出さない**
- 出力結果に対して、人が**納得・理解できない**ケースが多い
- 特に LLM では、**創発的な挙動**が人間にとて予測困難
- 「説明できない AI」は、社会的信頼を失うリスク

これまでの主な取り組み

- **可視化手法** (Attention Map、SHAP、LIME など)：画像・特徴量に特化
- **ルール抽出・事後説明型 XAI**：決定木や説明生成モデル
- **生成系 XAI** (例：GPT による説明生成)：文脈に応じた自然言語説明を試みるが、一貫性・根拠の妥当性に課題

可視化手法の例

- Circuit Tracing: Revealing Computational Graphs in Language Models
- 「ここでニューロンが発火している」という、LLM の判断基準部分が可視化されている。
- しかし発火に至る判断過程は不明 → 人間が目で見て、ラベリングしている



ニューロン発火パターンの
可視化(anthropic)

説明可能 AI (XAI) の究極のゴール

XAI が目指すもの

- 説明可能 AI (XAI) の究極のゴールは、
→ AI が内部で使っている "AI 言語" を人間が理解できる形で翻訳すること

現在の課題

- 可視化手法：ニューロンの発火は見えるが、人手でのラベリングに依存
- 既存の説明手法：未知のデータセットに対して、毎回人手でラベリングが必要
- 根本的問題：AI 内部の「意味」を人間が理解できる形で自動抽出する仕組みが不十分
→ 人手に依存しない自動説明生成の仕組みが求められている

本研究の位置づけ

中間ステップとしてのアプローチ

- 「AI 言語の翻訳」に向けた中間ステップとして、
2つのテキスト集合の意味的な差（対比因子）を説明させるタスクを設計
- 差異に含まれる意味を自然言語で取り出せれば、
→ AI 内部で発生している意味のラベル化・可視化が可能

本研究の貢献

- LLM による「**対比因子生成**」というタスクの実現可能性
- 二つのテキスト集合の差異を **自然言語で説明させるプロンプト設計**
- LLM による出力の**正確さ・具体性・再現性**を定量的に評価

研究アプローチ

本研究のアプローチ概要

- GPT にプロンプトを与え、グループ A/B のレビュー集合を入力
- GPT は、グループ A にのみ特徴的な差異を自然言語で記述
- 出力された説明が「対比因子」として妥当かを評価

本研究における「対比因子」とは？

「A に含まれて B に含まれないテキスト的特徴」

- 例：「A は価格に関する言及が多い」
- 抽象的な特徴ではなく、**文中の傾向・パターン**として表現される差異
- LLM がこれを自力で抽出できるかを評価

使用プロンプトの構造

以下の2つのデータグループを比較して、グループAに特徴的で
グループBには見られない表現パターンや内容の特徴を特定してください。

{examples_section}

【グループA】

{group_a_text}

【グループB】

{group_b_text}

{output_language}で{word_count}程度で、
グループAに特徴的でグループBには見られない
主要な違いを簡潔に回答してください。

具体例：ゲームレビューでの対比因子抽出

グループ A (ストーリー重視)

- "Amazing storyline" (素晴らしいストーリー)
- "The plot is engaging" (プロットが魅力的)

グループ B (技術面重視)

- "Good graphics" (良いグラフィック)
- "Nice sound effects" (良い音響効果)

期待される対比因子

→ "story and narrative" (ストーリーと物語性)

LLM に与えられる課題：この対比因子を自動で発見・言語化できるか？

評価の流れ

1. A/B グループを「特徴（例：価格）」で分離しておく
この**特徴を正解ラベルとする**
2. A/B グループを入力 → LLM 出力（例：「**グループ A は価格に言及している**」）
3. LLM 出力と正解ラベルを比較して、二つの類似度を 0~1 のスコアとして算出
→ どれだけ“意味的に近い”説明が生成できたかを測定

出力評価方法

意味的類似度を使った自動評価

- **BERT (Bidirectional Encoder Representations from Transformers ※1)** スコア
 - 意味空間でのベクトル類似（意味レベル）
- **BLEU (Bilingual Evaluation Understudy ※2)** スコア
 - n-gram ベースの表層一致（語彙レベル）

※1: Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv preprint arXiv:1810.04805. <https://arxiv.org/abs/1810.04805>

※2: Papineni, K., Roukos, S., Ward, T., & Zhu, W. J. (2002). BLEU: a Method for Automatic Evaluation of Machine Translation. In Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL), (pp. 311-318). <https://aclanthology.org/P02-1040/>

実験

実験の目的とアプローチ

- 目的：LLM が「対比因子」をどの程度適切に生成できるかを **定量的に評価**
- 手法：
 - 2 種類のデータセットに対して、異なる検証軸で GPT に説明生成を行わせる
 - 出力を BERT/BLEU スコアで評価
- 検証軸：
 - Few-shot の効果
 - アスペクトの難易度
 - データセットごとの差異

実験条件の詳細（変数と設定）

使用データセット

1. SemEval レストランレビュー

- 例："good food, great price, gread!"
- 含有アスペクト："food", "price", "service"

2. Steam ゲームレビュー

- 例："great sounds and story I have ever played"
- 含有アスペクト："audio", "story"

*1: Pontiki, M., Galanis, D., Papageorgiou, H., Androutsopoulos, I., Manandhar, S., AL-Smadi, M., ... & Peev, V. (2014). SemEval-2014 Task 4: Aspect Based Sentiment Analysis. In Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014), (pp. 27-35). <https://aclanthology.org/S14-2004/>

*2: ilos-vigil. (2024). Steam Review Aspect Dataset. GitHub. <https://github.com/ilos-vigil/steam-review-aspect-dataset> Kaggle.

<https://www.kaggle.com/datasets/ilosvigil/steam-review-aspect-dataset> Licensed under CC BY 4.0.

変数と固定要素

項目	設定内容
グループの件数	各 300 件 (A/B) で固定
Few-shot 設定	0-shot / 1-shot / 3-shot
使用 LLM	GPT-4o-mini (固定)
評価指標	BERT / BLEU スコア

実験設計

- Few-Shot 例題数を変えて出力を生成し、説明精度の傾向を比較・分析

評価方法の詳細

評価指標

- BERT スコア (意味類似度)
- BLEU スコア (語彙一致度)

評価の流れ

1. 正解ラベルと LLM 生成テキストを比較
2. 類似度を 0~1 で数値化
3. 高いスコア = より正確な対比因子の抽出

評価例と実験設定

具体的な評価例

- 正解ラベル：「価格」
- GPT 出力：「グループ A は価格に言及」
- 結果：BERT スコア: 0.76、BLEU スコア: 0.00

実験設定

- temperature: 0.7
- seed: 42
- ランダム値を固定して再現性を確保

結果

データセットごとの平均値

データセット	BERT	BLEU
SemEval	0.718	0.015
Steam	0.672	0.014

- どちらも BERT が高く BLEU が低い。
- 単語レベルでの一致などが少ない
- → 意味的には正解ラベルと LLM の出力が一致している

Steam ゲームレビューの結果概要

全体統計

指標	値
総実験数	24 件
平均 BERT スコア	0.5506
平均 BLEU スコア	0.0067
BERT スコア範囲	0.4400 - 0.8240
BLEU スコア範囲	0.0000 - 0.0800

- **BERT スコアは中程度**：意味レベルでの一致は確認できるが、抽出の精度はアспектに依存
- **BLEU スコアは極めて低い**：語彙レベルの一致がほとんど発生していない（自由生成傾向）

Few-shot ごとの平均値

Shot 設定	BERT	BLEU
0-shot	0.5114	0.0000
1-shot	0.5742	0.0100
3-shot	0.5662	0.0100

- 例題でスコアが向上 : 0 → 1-shot でスコアが向上している
- 例題数の影響は小 : 1-shot と 3-shot の差は小さい

Few-shot による性能変化の具体例（例：gameplay）

Shot	BERT	BLEU	説明語彙の例
0	0.529	0.000	グループ A はゲームの具体的なメカニクスや比較に焦点を当てている。
1	0.824	0.080	gameplay mechanics and exploration
3	0.824	0.080	gameplay mechanics and exploration

- Few-shot による出力の変化：例示によって、レビュー グループ A と B の差異を説明する → 特定する語彙にシフト

アスペクト別の平均スコア（高い順）

アスペクト	BERT	BLEU
gameplay	0.726	0.054
story	0.592	0.000
audio	0.554	0.000
visual	0.535	0.000
price	0.528	0.000
technical	0.520	0.000
suggestion	0.477	0.000
recommended	0.475	0.000

- gameplay/story など“ゲーム体験の内容”に関する語は高精度

考察：Steam レビューにおける特徴

- gameplay や story のような語彙的に安定した特徴は抽出しやすい
- recommendation や suggestion は文脈的・抽象的で難易度が高い
- few-shot により、LLM が抽出タスクに適した出力へ矯正される傾向

PyABSA SemEval レストランレビューの結果概要

全体統計

指標	値
総実験数	12 件
平均 BERT スコア	0.681
平均 BLEU スコア	0.022
BERT スコア範囲	0.554 - 0.771
BLEU スコア範囲	0.000 - 0.080

few-shot による分析

Shot 設定	実験数	平均 BERT スコア	平均 BLEU スコア
0-shot	4 件	0.606	0.005
1-shot	4 件	0.730	0.022
3-shot	4 件	0.708	0.040

- **1-shot で大幅な性能向上:** 0-shot → 1-shot で BERT スコアが 0.606 → 0.730 に向上
- **例題効果:** わずか 1 つの例示で LLM の出力精度が劇的に改善
- **3-shot での安定化:** BLEU スコアも 0.005 → 0.040 と 8 倍向上

アスペクトごとの比較

以下は food アスペクトでの例：

Shot0,1,3	BERT スコア	BLEU スコア	LLM 応答
0-shot	0.554	0.000	"Group A emphasizes staff friendliness and authenticity."
1-shot	0.743	0.033	"Focus on food quality and dining experience."
3-shot	0.771	0.080	"food quality and presentation"

- **0-shot:** food 関連語彙が出現せず
- **1-shot:** "food quality" が出現開始
- **3-shot:** "presentation" など詳細化
- **結論:** 例示により LLM 出力が正解方向に強化

service 着目

特に service でも同様の変化が見られる：

Shot 設定	BERT スコア	BLEU スコア	LLM 応答
0-shot	0.672	0.009	service quality (全体評価)
1-shot	0.753	0.054	service quality and attentiveness
3-shot	0.758	0.080	service and dining experience

- **語彙の具体化:** "attentiveness" (注意深さ) などの詳細な表現が導入
- **アスペクトの精緻化:** 抽象的な概念から具体的な特徴へと発展
- **BERT スコア向上:** より詳細な語彙が意味類似度の改善に寄与

アスペクト別平均スコア（高い順）

抽象度の高い概念でも、十分な例示があれば抽出可能という傾向が見られる。

アスペクト	BERT スコア	BLEU スコア
service	0.728	0.048
food	0.689	0.038
atmosphere	0.663	0.000
price	0.644	0.004

- **主観的概念が高スコア**: service・food は頻出語彙で安定した抽出が可能
- **price は低スコア**: 定量的だが表現が抽象的（「高い」「コスパ悪い」）で抽出困難

SemEval レストランデータセット結果まとめ

Shot 設定	実験数	平均 BERT スコア	平均 BLEU スコア
0-shot	4 件	0.606	0.005
1-shot	4 件	0.730	0.022
3-shot	4 件	0.708	0.040

- **1-shot 効果:** 対比因子語彙 ("food quality", "staff attentiveness") が出現し、BLEU スコア上昇
- **3-shot 限界:** 内容充実する一方、焦点散漫化で BERT スコア低下のケースあり

Steam 実験との比較

指標	PyABSA 平均	Steam 平均
BERT 類似度	0.681	0.725
BLEU スコア	0.022	0.027

PyABSA の特徴：

- Steam より低スコアだが、抽象語彙・文体揺らぎが大きくタスク難易度が高い
- 情報密度・多様性では PyABSA が上回る
- Steam は英語として単純明快で対比構造が分かりやすい

5. 考察

考察 ① : Few-shot の効果と限界

Few-shot の効果

- 0-shot では曖昧な説明が多く、差異の特定が困難
- 1-shot 以上で、語彙の精度や焦点の明確化が顕著
 - 例：「food」 「service」 「recommendation」 などのアスペクト語が登場
- 3-shot によって語彙がさらに詳細化される傾向
 - 例：「attentiveness」 「presentation」 などの具体的表現
- → Few-shot により、説明が“伝える”から“特定する”へと最適化

Few-shot の限界

- スコアの伸びが 1-shot で頭打ちになるケースがある
 - 3-shot では焦点が分散し、BERT スコアが低下する場合も
- 抽象的・主観的なアスペクト (suggestion など) は依然困難
- BLEU スコアは低水準で停滞
 - → 語彙の一致よりも、表現の多様性が影響している可能性

考察 ②：対比因子抽出の難しさと LLM の特性

アスペクトごとの難易度

- 高スコア (gameplay, food, service)
 - 語彙が安定・頻出しやすく、差異が言語的に現れやすい
- 低スコア (recommended, suggestion)
 - 概念的・メタ的であり、テキストから直接抽出が困難
- → LLM の生成傾向とズレやすい

LLM の応答スタイルの影響

- LLM は「共感的・抽象的」な表現を好む傾向
- → 0-shot では説明が曖昧になりがち
- Few-shot によって「比較的で説明的」なスタイルに矯正可能
- → 例示は LLM にとっての出力スタイルの“教師”となる

6. 結論と貢献

研究の結論

- GPT を用いた 対比因子生成の可能性と限界を定量評価した
- Few-shot プロンプティングにより最大 20% 程度のスコア向上
- 特に 1-shot 設定での効果が顕著
- 一部アスペクトでは、人間にとっても納得感のある出力が得られた

本研究の貢献

- LLM を活用した 対比因子生成タスクの枠組みを初提案・検証
- 評価手法 (BERT/BLEU) による定量的分析フレームワークを構築
- Steam / SemEval という異なるジャンルでの 再現可能な比較実験
- 創発言語の意味理解という XAI 研究への中間的貢献を達成

7. 今後の展望

評価と改善の方向性 1

- 評価指標が BERT,BLEU のみで、文脈的な判断ができない
 - 人手による説明の主観評価（納得性・簡潔性・明瞭さなど）の導入

評価と改善の方向性 2

- データセットがレビュー系のみ
 - 感情分類など、より抽象度の高いデータセットでの検証
 - 例：GoEmotion データセットなど

評価と改善の方向性 3

- ベースライン手法
 - 基準となる手法が検討できていない（データセットのアスペクト同士のスコアを現在基準としている）
 - TF-IDF 等、LLM 以外によるアプローチでのベースラインを考える

長期的なゴール

- 本研究で得られた知見を踏まえ、
- 創発言語の意味理解フレームワークの一部として統合
- “言語を創る AI”と“その意味を理解する人間”的接続点の創出

ご清聴ありがとうございました