

大規模言語モデルを用いた 対比因子ラベル生成手法に関する研究

博士前期課程 最終発表

若林研究室 202421675 清野駿

発表の流れ

- 背景・問題意識・目的
- 問題設定：対比因子ラベル生成タスク
- 手法：LLM による対比因子ラベル生成
- 実験：データセット／設計
- 結果・考察
- まとめと今後の課題

背景・問題意識

- 深層学習は高性能だがブラックボックスで、判断根拠を説明できないと信頼・説明責任の面で課題があった
- 従来の説明可能 AI による、特徴に焦点を当てた説明（この画像のこのピクセルは重要度が高い、など）は説明が不安定になりやすく、概念として理解しにくい

- 近年、モデル内部の中間表現から潜在的な概念特徴を発見する研究が進展
ただし、その概念が何を意味するかの命名は人手に依存しがち

人手での命名作業の例



受話器付きの携帯電話を手を持っている



複数の携帯端末が並んでいる



携帯電話とリモコン等が置かれている

→命名：概念Aは **モバイルデバイス** に対応すると考えられる

- しかし、人手での命名は作業コストが高く、判断が主観的で再現性に課題

本研究の位置づけ

- 先ほどの課題を解決するため、概念に対して自動で命名する手法が研究されてきた
- 近年は LLM による自動解釈（差分説明など）も提案されている
- しかし LLM による自動解釈が、人手による解釈をどの程度再現できるかが体系的に検証されていない
- **目的**：正解アスペクトによって分割した（人手で正解が付与されている）データセットを用いて、LLM がどれだけ概念に対して妥当なラベル生成をできるか検証すること

問題設定：対比因子ラベル生成タスク

入力：2つのテキスト集合 A, B

$$\text{textContrastiveLabeling}(A, B) \mapsto L$$

- A ：ある特徴を含むテキスト集合
- B ：ある特徴を含まないテキスト集合
- **対比因子ラベル L** ： A と B を分ける主要な要因（対比因子）を表す短いフレーズ

例：A に価格・コスパ不満テキストが多い → high prices and poor value for money

手法：LLM による対比因子ラベル生成

- グループ A/B の代表テキストを入力として提示し、両者を分ける対比因子ラベル L を生成させる
- 例題を挿入する場合：冒頭に「グループ $A/B \rightarrow$ 対比因子ラベル」の入出力例を置き、出力の形式・語彙を誘導する

以下の2つのデータグループを比較して、グループAに特徴的でグループBには見られない主要な対比因子を特定してください。

(必要ならここに【例題】を挿入)

【グループA】

- ...
...

【グループB】

- ...

英語で5-10語程度の対比因子ラベルとして、簡潔に回答してください。

実験

- LLM が生成する対比因子ラベルの品質を、実務的な環境で定量評価する
- そのために、アスペクトが付与済みのデータセット（商品レビュー等）を用いる
- 各アスペクト（価格、サービス等）について、アスペクトを含む／含まないテキスト群を A/B の 2 グループに分割。LLM は A/B を入力として、 A に特徴的で B に見られない要素を対比因子ラベル L として生成する
- 生成した対比因子ラベルと正解ラベル（アスペクト名）の一致度を、意味的一致（SBERT 類似度）と語彙的一致（BLEU）および LLM による 5 段階の評価で測定する

実験：使用データセット

本実験では以下の4つのデータセットを用いる

- **SemEval-2014 ABSA**：商品レビューデータセット。Food/Service/Battery/Screen の4アスペクトを使用。
- **GoEmotions**：感情分類データセット。驚き、喜びなどの28アスペクトで構成される。
- **Steam**：ゲームレビューデータセット。Gameplay/Visual/Story/Audio の4アスペクトを使用。レビュー長が上記二つよりも長い。
- **COCO Retrieved Concepts**：画像キャプションデータセット。コサイン類似度によるクラスタリングで画像ベクトルをいくつかのクラスタに分類後、各クラスタの画像のキャプションを用いてグループA/Bを作成した。正解ラベルなし。

実験：設計

6つのカテゴリに分けて実験を行う

- **共通設定**：生成モデルは GPT-4o-mini、AB グループそれぞれ 100 テキストで比較

1. **データセット別比較**：SemEval-2014、GoEmotions、Steam で特性の違うデータセット間での性能差を検証
2. **Few-shot 実験**：0/1/3-shot で例示数の影響を検証
3. **グループサイズ比較**：group_size (50-300) で入力テキスト数の影響を検証
4. **モデル比較**：GPT-4o-mini vs GPT-5.1 でモデル差を検証
5. **アスペクト説明文比較**：評価時にアスペクト名の代わりに説明文を使用
(例："gameplay" → "this review contains gameplay" vs LLM 生成ラベル)
6. **COCO 実験**：正解ラベルなしデータセットで未知概念への命名性能を検証

実験 1：データセット別比較

データセット(アスペクト数)	平均単語数	平均 SBERT 類似度	平均 BLEU	平均 LLM 評価
SemEval-2014 (4)	19.9	0.7481	0.0151	0.5500
GoEmotions (28)	12.8	0.7055	0.0049	0.4714
Steam (4)	244.7	0.5328	0.0000	0.2500
全体 (36 条件)	17.8	0.6910	0.0055	0.4556

- **SemEval/GoEmotions でスコア高**：特に SemEval では 0.74 と一定の意味的相関が見られた。長文の Steam では性能が低下した。
- **評価指標の妥当性と相関**：意味類似度（SBERT）と LLM 評価には強い正の相関（ $\rho = 0.73$ ）を確認でき、提案手法の妥当性が示された。

実験 1：生成例

SemEval / food

- 正解： food
- 生成： Focus on food quality and service experiences.
- food のように直接語彙が出やすい条件 → 差分が一点に集まってわかりやすい

GoEmotions / anger

- 正解： anger
- 生成： Group A features aggressive language and strong emotional expressions.
- anger を直接言わない間接表現 → BLEU（語彙的一致）は 0 になるが SBERT（意味的一致）は文脈を拾える

実験 2：Few-shot（Steam 4 アスペクト）

例題数	平均 SBERT 類似度	平均 LLM 評価
0-shot	0.5526	0.3000
1-shot	0.6530	0.3500
3-shot	0.5754	0.4000

- **1,3-shot でスコア最大**：1-shot で BERT が最大化、3-shot では LLM 評価が最大化するなど、例示数増加が全指標を一律に改善させるわけではない。
- shot 数間で有意差はなく ($p = 0.47$)、手法の工夫（Few-shot）による変動よりも、アスペクト自体の抽出難易度、つまりデータセットの性質が結果に影響すると考えられる。

実験 3：グループサイズ比較（Steam 4 アスペクト）

group_size	SBERT 類似度	LLM（平均）
50	0.5455	0.3000
100	0.5436	0.3500
150	0.5321	0.2500
200	0.5396	0.3000
300	0.5375	0.2000

- サンプルサイズ = 集合 A,B からいくつのテキストをプロンプトに含めるか
- 結果：サンプル数を増やしても性能は向上しなかった。
- サンプル数の増加は差分に関係のない周辺話題（ノイズ）の混入を招く。その結果、抽出すべき対比の焦点がぼやけたと考えられる。

実験 4：モデル比較（Steam 4 アスペクト）

モデル	平均 SBERT 類似度	平均 LLM 評価
4o-mini	0.5453	0.3000
5.1	0.5375	0.2500

- 最新の大型モデル（GPT-5.1）が軽量モデル（4o-mini）を一貫して上回る傾向は見られず、平均性能に統計的な有意差（ $p = 0.875$ ）は認められなかった。

実験 5：アスペクト説明文比較（Steam）

全体結果平均

条件	平均 SBERT 類似度	平均 LLM 評価
アスペクト 名比較	0.5395	0.2500
アスペクト 説明文比較	0.5496	0.3000

アスペクト別SBERT平均

カテゴリ	アスペクト 名比較	アスペクト説 明文比較
Gameplay	0.5335	0.5523
Visual	0.5311	0.5186
Story	0.5392	0.5467
Audio	0.5544	0.5810

- アスペクト説明文では全体として改善傾向を示したが、統計的有意差は認められなかった（Wilcoxon $p = 0.3750$ ）。わずかな改善はあるが効果は限定的になることがわかった。

実験 6 : COCO Retrieved Concepts (概要)

- COCO train2017 を CLIP で類似度分割し、各コンセプトで A=Top-100 / B=Bottom-100 のキャプション差分からラベル生成
- クラスタリングされた画像キャプション群において、あるクラスタに含まれる・含まれない画像のキャプション群 A/B のみを頼りに命名
- 正解ラベルがないため、代表画像との整合で成功/失敗要因を分析
- ※ LLM への入力画像ではなく「キャプションテキスト」のみ

実験 6 : COCO Retrieved Concepts (成功例)



A artistic picture showing an old fashion handset for a phone and a cell phone.



A group of cellphones, all different shapes, sizes and brands.



Three electronic devices sitting close together on a wooden surface.

生成ラベル (concept_50) : Group A focuses on electronics and mobile devices.

単一概念 (携帯/電子機器) にまとめ、語彙手がかかりが強い → ラベルが具体化しやすい

実験 6 : COCO Retrieved Concepts (失敗例)



A traffic light suspended in a white sky with a green signal.



An airplane is flying high in the sky.



An inside view of an apartment, showing a guy and two electric guitars.

生成ラベル (concept_0) : Group A features everyday scenes and objects, ...

- グループ内で概念が混在 → 差分がぼやけ、ラベルが抽象化/一般化しやすい

実験 6：総括（coco）

- 成功条件：集合が単一概念としてまとまる／語彙手がかりが強い
- 失敗条件：概念混在・周辺話題の混入で差分が弱い
- 示唆：正解ラベルがなく人間にとって意味づけしづらい類似度構造でも、差分から妥当な概念語を付与できた例があり、未知概念ラベリングに可能性

結論

- SBERT 類似度は平均 0.69 程度で、最大 0.74 と一定の効果が見られた
- 短文・単一概念にまとまる条件で安定し、長文/ノイズ混入で性能が落ちやすい
- 正解なしの未知の概念（中間表現）へのラベリングでも成功する例があった
- **示唆**：一定の条件下で効果発揮、ただしデータセットの性質に結果が左右される傾向

今後の展望

- **評価指標の拡張**：特に被験者実験を通じた人手による評価が望ましい
- **実際のモデル内部での命名検証**：実際の深層学習モデル内部から抽出された概念を対象に，LLM による命名が人手による解釈をどの程度再現するのかを検証することが今後の課題

目次（再掲）

- 背景・問題意識・目的
- 問題設定：対比因子ラベル生成タスク
- 手法：LLM による対比因子ラベル生成
- 実験：データセット／設計
- 結果・考察
- まとめと今後の課題

Q: 既存の LLM 命名と何が違う？（新規性）

A: 手法提案だけでなく、外部ラベル付きデータセットで定義した (A/B) を入力に、LLM が 既存アスペクト（外部スキーマ）をどれだけ再発見できるかを複数データセット × 複数条件で体系的に定量評価した点。

Q: 「概念」と「アスペクト」は同じ？（タスク定義）

A: 同一ではない。

概念 → 深層学習モデルの中間表現において、複数の入力に対して共通して発火する中間表現があった時、それら入力に共通して出る概念的な特徴

アスペクト → データセットに人手で付与されている、各データに現れる属性的な特徴
本研究では、命名対象（潜在概念）を想定しつつ、評価では **外部ラベル（アスペクト）** で (A/B) を代理定義して、命名モジュールの性能を測る。

Q: A/Bはどう作る？混入（ノイズ）は？

A: 原則 「対象アスペクトを含む」=A / 「含まない」=B。

GoEmotions はマルチラベル、Steam は複数アスペクト併記が多く、差分が分散しやすい → 性能低下要因として結果で議論。

Q: なぜ BLEU がほぼ 0 でも入れる？（指標の妥当性）

A: 語彙的一致があるかを定量的に測るため

指標の特性と実験の特性が今回はうまく一致しなかったため BLEU はほぼゼロ。ただし、SBERT（意味的類似度）は平均約 0.63 と一定の類似度を示した。

→ 語彙的一致は少ないが意味的類似度はあったので、語彙が一致せずとも意味的な部分で対比因子を抽出できていると考察できる。

Q: SBERT 類似度は何を使ってどう計算？（再現性）

A: SentenceTransformer `all-MiniLM-L6-v2` の埋め込みでコサイン類似度を計算し、 $\cos \in [-1, 1]$ を $(\cos + 1)/2 \in [0, 1]$ に正規化して使用。

Q: LLM 評価（5 段階）はバイアスにならない？

A: なるので **補助指標**として扱う。

評価は「参照テキスト vs 候補テキストの意味的類似度」を 1-5 で採点し、
temperature=0.0 で固定して再現性を確保。