

大規模言語モデルを用いた対比因子ラベル生成手法に関する研究

筑波大学

人間総合科学学術院人間総合科学研究群

情報学学位プログラム

2026年3月

清野 駿

大規模言語モデルを用いた対比因子ラベル生成手法に関する研究

A Study on Contrastive Factor Label Generation Method Using Large Language Models

氏名：清野 駿
Seino Shun

深層学習モデルは多様なタスクで高い性能を示している一方で、その内部処理は依然としてブラックボックス性が高く、意思決定の根拠や内部で表現される概念を人間が理解することは容易ではない。この問題を解決する試みとして、モデル内部の中間表現を Sparse Autoencoder などを用いて少数の離散的な特徴に分解し、抽出された離散特徴をモデルが捉えている潜在概念として対応づける研究が進展している。一方で、抽出されたそれぞれの潜在概念に対応する意味を、その潜在概念が反応する入力テキスト集合に基づいて解釈する作業は、人手によって行われているのが現状である。この人手作業の負担を軽減するために、大規模言語モデル (Large Language Model; LLM) を用いた自動化が検討されているが、LLM が人手による解釈をどの程度再現できるかが体系的に検証されていない。

本研究の目的は、特定の潜在概念が反応するテキスト集合に基づいて、その潜在概念に対応する意味を表す自然言語ラベルを生成する設定での LLM の性能を定量的に評価することである。そのために、ある既知の特徴を含む・含まないの条件で構成されたテキスト集合 A/B に対して、A に含まれて B に含まれない特徴を自然言語ラベルで生成するという対比因子ラベル生成タスクを提案し、LLM が対比因子ラベル生成タスクにおいて妥当な自然言語ラベルを生成できるかを複数データセットを用いて横断的に検証した。手法としては、A/B の代表テキストを LLM に入力し、Few-shot 例示 (0/1/3-shot) を与えたプロンプトにより、両集合を分ける特徴を自然言語で生成させる。評価には SemEval-2014 ABSA (Restaurants/Laptop), Steam ゲームレビュー, GoEmotions, COCO Retrieved Concepts など複数ドメインを含むデータセットを用い、各グループ 100 件の条件で GPT-4o-mini を含む複数モデルを比較した。生成されたラベルの品質は、Sentence-BERT (SBERT) による埋め込み類似度 (SBERT 類似度), BLEU, および LLM による意味的類似度評価を組み合わせ、多角的に測定した。

実験の結果、全 36 条件の平均で SBERT 類似度は約 0.698 と中程度の意味的一致を示した一方、BLEU は 0.008 と語彙レベルの一致は低かった。また Few-shot では 1-shot が最も良好で、出力が「説明的な文章」から「より一意に特定可能な語彙」へと安定する傾向が見られた。さらに gameplay や food のような語彙的に具体的・安定した概念では高いスコアを示し、抽象度の高い概念では低下する傾向が確認された。これらの結果から、提案手法は一定の条件下において、人手による解釈ラベリングを部分的に代替し得ることが示された。ただし、概念が抽象的な場合の説明の難しさや、語彙が一致しない場合の文脈を汲み取った評価ができない問題など、今後解決すべき課題も明らかになった。

主研究指導教員：若林 啓
副研究指導教員：伊藤 寛祥

目次

第1章 序章	1
第2章 関連研究	4
2.1 従来の事後説明手法とその限界	4
2.1.1 特徴量帰属手法の限界	4
2.1.2 集合レベル説明の欠如	4
2.1.3 反事実的説明	5
2.2 非教師ありコンセプト発見と命名の課題	5
2.2.1 人手ラベリングへの依存	6
2.2.2 非教師あり概念抽出とメカニスティック解釈の命名問題	6
2.2.3 自動概念命名と自動解釈パイプラインの系譜	7
2.3 LLM を用いた自動ラベル生成と対比的要約	7
2.3.1 LLM による自動ラベル生成	7
2.3.2 対比的要約とテキスト分布差分の記述	8
2.3.3 本研究の位置づけと新規性	8
2.4 本章のまとめと本研究の位置づけ	9
第3章 提案手法	10
3.1 対比因子ラベル生成タスクの定式化	10
3.2 LLM による対比的要約の実行	11
3.3 Few-shot ICL の設計	12
第4章 評価実験	13
4.1 実験の目的と概要	13
4.2 データセット	14
4.2.1 Steam Review Aspect Dataset	14
4.2.2 SemEval-2014 ABSA (Restaurants)	15
4.2.3 GoEmotions	16
4.2.4 Retrieved Concepts (COCO Captions)	16
4.3 実験設定	17
4.3.1 実験パイプラインの概要	17
4.3.2 LLM モデルとパラメータ設定	17
4.3.3 プロンプト設計	17
4.3.4 データの前処理と分割方法	18
4.3.5 Few-shot 例の作成方法	18
4.3.6 実験カテゴリの定義	19
4.3.7 比較手法とベンチマーク	19
4.4 評価指標	19

4.4.1	BERT スコア (Sentence-BERT 類似度)	19
4.4.2	BLEU (Bilingual Evaluation Understudy)	20
4.4.3	LLM 評価スコア	20
4.5	統計的分析	21
4.5.1	繰り返し測定 (ブロック) と多水準比較	21
4.5.2	2 条件比較	21
第 5 章	結果と考察	22
5.1	データセット別比較	22
5.1.1	実験結果	22
5.1.2	考察	23
5.2	Few-shot 設定による性能比較	25
5.2.1	実験結果	25
5.2.2	考察	26
5.3	グループサイズの影響分析	27
5.3.1	実験結果	27
5.3.2	考察	27
5.4	モデル比較実験	28
5.4.1	実験結果	28
5.4.2	考察	29
5.5	アスペクト説明文の効果検証	29
5.5.1	実験結果	29
5.5.2	考察	30
5.6	COCO Retrieved Concepts 実験	30
5.6.1	実験結果	30
5.6.2	考察	35
第 6 章	まとめ	37
6.1	結論	37
6.2	今後の課題	37
	謝辞	39
	付 録 A 実験詳細	40
A.1	全アスペクトの結果	40
	参考文献	41

図 目 次

5.1	concept_0 の代表画像例. Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している	31
5.2	concept_1 の代表画像例. Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している	32
5.3	concept_2 の代表画像例. Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している	33
5.4	concept_10 の代表画像例. Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している	34
5.5	concept_50 の代表画像例. Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している	35

表 目 次

4.1	使用データセットの概要	13
4.2	実験カテゴリーの概要	14
4.3	評価指標の概要	14
4.4	テキスト統計の概要 (train/dev/test 合算)	14
4.5	実験カテゴリ別パラメータ設定 (変動項目のみ)	19
5.1	データセット別比較: データセット別評価スコア	22
5.2	データセット別比較: 主要アスペクト別評価スコア	23
5.3	データセット別比較: 全体統計	23
5.4	Few-shot 設定による性能比較: 平均スコア	25
5.5	Few-shot 設定による性能比較: アスペクト別 SBERT 類似度	25
5.6	グループサイズによる性能比較 (各 group_size での全アスペクト平均値)	27
5.7	グループサイズ比較実験: 全体統計	27
5.8	モデル比較実験: 平均スコア	28
5.9	モデル比較実験: アスペクト別 SBERT 類似度	28
5.10	アスペクト説明文の効果検証: 平均スコア	30
5.11	アスペクト説明文の効果検証: アスペクト別 SBERT 類似度	30
A.1	データセット別比較: 本実験で扱った全アスペクト別評価スコア	40

第1章 序章

近年の深層学習モデルは、医療、金融、自動運転といった社会的重要性の高いドメインにおいて優れた予測性能を達成している。しかし、その内部はブラックボックスであり、モデルの意思決定プロセスが人間にとって解釈不能であるという点は、信頼性・公平性・説明責任の観点から大きな課題として残り続けている。この問題に対処するため、モデルの判断根拠を人間にとって理解可能な形で提示する XAI (Explainable AI, 説明可能 AI) の研究が活発化している。例えば、Mersha ら [23] は XAI のニーズ・技術・応用を網羅的に整理し、医療、金融、自動運転などの高責任ドメインにおいて説明可能性への要求が急速に高まっていることを示している。また Vilone と Longo [25] は、2010 年以降の XAI 関連文献を体系的にレビューし、論文数の増加と応用分野の拡大を踏まえて、XAI が独立した研究トピックとして確立しつつあることを報告している。

従来、XAI の中心的な手法として広く普及してきたのは、LIME (Local Interpretable Model-agnostic Explanations) [2] や SHAP (SHapley Additive exPlanations) [3] に代表される事後説明 (post-hoc explanation) 手法である。これらはブラックボックスモデルの入出力関係をもとに、個々の予測に対する特徴量寄与を可視化するが、説明の忠実性やロバストネスが解析条件に大きく依存しうること、説明提供者にとって都合の良い説明だけを選択できてしまうこと、ピクセルやトークンといった低レベル特徴にとどまり集合レベルの意味構造を十分に説明できないことなど、根本的な限界が指摘されている。

こうした事後説明手法の限界を背景に、近年はモデルの中間表現の振る舞いそのものを解析対象とし、入力特徴の寄与可視化ではなく内部で表現される概念を単位として説明するアプローチが発展している。TCAV [6] に代表されるコンセプトベース XAI や、UCBM [16], CCE [39] に代表される非教師ありコンセプト発見は、いずれもモデルの中間表現 (ニューロン活性) への直接アクセスを前提に、内部で表現される概念を解析対象として扱う。この流れをさらに推し進め、モデルの中間表現だけでなく内部の計算メカニズムや回路構造そのものを解析対象とする MI (Mechanistic Interpretability, メカニスティック解釈) の研究も発展している。MI は、個々のニューロンや注意ヘッドなどの内部要素が担う機能を同定し、それらがどのように結合して出力に至るかを回路として記述することで、モデルの振る舞いをより因果的・構造的に理解することを目指す。さらに近年は、Sparse Autoencoder と LLM を組み合わせた自動解釈手法 [37, 38] により、発見された内部要素に対する自然言語による意味付けと、Simulation Score などの内部指標による忠実性評価が提案されている。しかし、これらの枠組みは主に、生成した説明が対象モデルの挙動をどの程度再現できるかを評価するものであり、LLM が人手による概念名や解釈をどの程度再現できるかは必ずしも検証されていない。この点は、中間表現 (ニューロン活性) への直接アクセスを前提とする設定においても、本研究の直接的な問題意識である。

一方、中間表現 (ニューロン活性) への直接アクセスを前提とせず、テキストや画像の集合・クラス・分布の差分をブラックボックスな LLM で記述する研究も現れている。Zhong ら [49] は 2 つのテキスト分布の違いを自然言語で説明するタスクを定式化し、大規模言語モデルを命題生成器と検証器として用いて、データセット解析やショートカット検出、ク

ラスタラベリングなどに応用している。VisDiff [50] は画像セット間の差分キャプション生成を行い、TopicGPT [51] や LLoM [52] はクラスタやトピックに対するラベル命名・概念帰納を LLM によって行うフレームワークを提案している。これらの研究は、二つの集合 A, B の差分を自然言語で要約するという点で本研究と技術的なフレームワークを共有しているが、多くはテキスト分類・トピックラベリング・データセット解析を主目的としており、XAI の観点からモデルや概念抽出器が持つ概念にどれだけ妥当な名前を付けられるかを系統的に評価することは主眼としていない。

本研究では、この技術的フレームワークを XAI 文脈の概念命名タスクとして具体化する。入力には 2 つのテキスト集合 A, B であり、LLM は両者を分ける意味的差分を短い自然言語フレーズとして出力する。本論文の実験では、SemEval-2014 ABSA, Steam Review Aspect Dataset, GoEmotions といったアスペクト付きテキストデータセットを用い、各アスペクトに対応する文集合をグループ A 、それ以外をグループ B として構成する。生成されたラベルが外部アスペクトスキーマの語彙とどの程度一致するかを、意味的一致度にもとづいて定量的に評価する。本研究では、二つのテキスト集合 A, B を入力とし、両者を分ける意味的な要因を自然言語フレーズ L として出力する写像を $\text{textContrastiveNaming}(A, B) \rightarrow L$ と書き、このとき得られる L を対比因子ラベルと呼ぶ。また、対比因子ラベルを生成するタスク全体を対比因子ラベル生成タスクと定義する。対比因子生成タスクは、概念特徴を持つサンプル群と持たないサンプル群の集合差分から、両者を分ける意味的な要因を人間が理解できる自然言語で要約することを目的とする。

これを踏まえて、本論文の目的は、対比因子ラベル生成タスクを通じて、LLM を XAI 用の概念命名モジュールとみなし、テキスト集合差分入力だけから既存のアスペクトスキーマの語彙をどの程度再発見できるかを、実務的データセット上で定量的に評価することである。とくに、レストランレビュー (SemEval-2014 ABSA)、ゲームレビュー (Steam Review Aspect Dataset)、感情分類 (GoEmotions) という異なるドメインにまたがって、具体的アスペクトと抽象的概念の違い、ドメイン特有のノイズやマルチアスペクト性、Few-shot インコンテキスト学習 (ICL) やグループサイズ、説明文の有無といったプロンプト設計の違いが、対比因子ラベルの品質にどのような影響を与えるかを明らかにする。さらに、視覚的概念に対する拡張可能性を検証するため、CLIP 類似度と COCO キャプションにもとづく Retrieved Concepts データセットに対しても同様のタスクを適用し、テキストキャプション差分から視覚的概念をどの程度言語化できるかを検討する。

本論文では、上記の対比因子ラベル生成タスクを解くための手法として、大規模言語モデル (本論文では主に GPT-4o-mini) を用いた対比因子ラベル自動生成手法を用いる (詳細は第三章で述べる)。具体的には、各アスペクトについて構成したグループ A と B のテキストリストをプロンプトとして提示し、「グループ A に特徴的でグループ B には見られない主要な違いを、英語で 5-10 語程度のフレーズとして答えるように指示する」ことで、対比因子ラベルを生成させる。生成されたラベルと元のアスペクトラベルとの意味的一致度を、SBERT 類似度や BLEU, LLM による意味類似度評価などの自動指標によって定量的に測定し、LLM による対比因子ラベル生成の達成度と限界を評価する。

本研究の貢献は次の三点に要約される。第一に、Zhong ら [49] によるテキスト分布間差分の自然言語記述フレームワークを踏まえつつ、ABSA、感情分類、ゲームレビューといった実務的アスペクトスキーマを外部基準として用い、LLM がテキスト集合差分から既存アスペクト名をどこまで再発見できるかを測る XAI 向け対比因子ラベリング・ベンチマークを構築した。第二に、UCBM や CCE を含む任意の概念抽出手法が返す「概念特徴を持つ／持たない」サンプル集合を入力とし、LLM を汎用的な命名モジュールとして利用するプ

ロンプト設計と評価パイプラインを提示し、Few-shot ICL, グループサイズ, モデル種別, アスペクト説明文の有無といった設計選択が対比因子ラベルの品質に与える影響を体系的に分析した. 第三に, SBERT 類似度, BLEU, LLM 評価およびエラー分析にもとづき, 具体的アスペクト／抽象的概念／ノイズの大きいドメイン／視覚概念といった異なる条件において, LLM による対比因子ラベル生成がどの程度 XAI の説明単位として有効か, どのような限界を持つかを具体的に明らかにした.

本稿の構成は次のとおりである. 第二章では, 従来の XAI 手法, 非教師ありコンセプト発見, モデル内部の自動解釈, およびテキスト・画像集合の差分を自然言語で記述する先行研究を概観し, 本研究の位置づけを明らかにする. 第三章では, 対比因子ラベル生成タスクを定式化し, 大規模言語モデルを用いた対比因子ラベル自動生成手法と Few-shot 設計, 評価指標の設計について述べる. 第四章では, 使用したデータセットと実験パイプライン, LLM のパラメータ設定を説明し, 各種実験の内容と結果を報告する. 第五章では, 得られた結果にもとづき, データセット特性やプロンプト設計が性能指標に与える影響と限界について考察する. 第六章では, 第五章の結果を横断して総合的に考察する. 第七章では, 結論と今後の課題をまとめる.

第2章 関連研究

本章では、第一章で述べた問題設定と貢献を踏まえ、本研究が位置づけられる枠組みと残されたギャップを整理する。特に、(1) 個別インスタンス中心の事後説明、(2) 概念ベース XAI・非教師ありコンセプト発見・メカニスティック解釈、(3) LLM による自動ラベル生成と対比的要約、の三領域を取り上げ、それぞれがどこまで集合レベル／概念レベルの説明と命名を実現しているかを概観する。

2.1 従来の事後説明手法とその限界

深層学習モデルのブラックボックス性に対処するため、初期の XAI 研究は主に、特定の予測に対する入力特徴量の寄与度を事後的に可視化する手法に焦点を当ててきた。

2.1.1 特徴量帰属手法の限界

最も広く用いられてきた手法として、LIME (Local Interpretable Model-agnostic Explanations, Ribeiro et al., 2016) [2] や SHAP (SHapley Additive exPlanations, Lundberg & Lee, 2017) [3] が挙げられる。LIME はターゲットとする予測の周囲で入力を摂動し、局所的に解釈可能な代理モデル（サロゲートモデル）を構築することで個々のインスタンスの予測根拠を可視化する。SHAP はゲーム理論に基づく Shapley 値を用いて特徴量の貢献度を統一的な枠組みで定量化する。

しかし、これらの事後説明手法には、少なくとも三つの観点から根本的な課題が指摘されている。第一に、説明の忠実性・ロバストネスの問題である。Slack らは、実データ上では差別的な決定境界を持つモデルと、摂動サンプル上でのみ用いられる見かけ上公平なモデルを組み合わせることで、LIME や SHAP が後者の挙動のみを説明し、真の判断根拠を偽装できることを示した [21]。また、Alvarez-Melis と Jaakkola は、距離空間上で十分近い入力ペアに対して説明もまた十分近くあるべきだとするロバストネス基準を定式化し、多くの特徴量帰属手法がこの条件を満たさないことを理論解析と実験の両面から示している [22]。第二に、倫理的・規制的な透明性の観点からの問題である。Bordt らは、事後説明アルゴリズムが本質的な曖昧さを持ち、敵対的な状況では都合の良い説明だけを提示できてしまうため、GDPR における説明責任などの目的とは両立しにくいと批判する [20]。Rudin も、高責任ドメインにおいてブラックボックスモデルに事後説明を付与するよりも、当初から解釈可能なモデルクラスを用いるべきだと主張している [24]。

2.1.2 集合レベル説明の欠如

以上のように、従来の事後説明手法は、個々の予測に対する特徴量寄与の可視化という観点からは一定の有用性を持つ一方で、(1) 真の判断根拠の再現性や (2) 倫理的操作性に

関する問題を抱えている。本研究にとって特に重要なのは、(3) モデルが特定のデータ集合全体に対してどのような意味的性質を学習しているのかを、集合レベルのパターンとして直接記述する手段が乏しいという点である。

特徴量帰属手法の出力は、画像における重要なピクセルやテキストにおける重要な単語といった低レベルな特徴量の寄与スコアにとどまり、例えば高価格だがサービスが良いレビュー群のように、集合レベルの意味的なまとまりを直接記述することはできない。Haedeker らは、多数の事例から類似サンプルをクラスタリングし、各クラスタの共有する特徴を自然言語で記述することでグループレベルのパターンを説明する手法を提案しており、既存のローカル説明では集合レベルの振る舞いを十分に捉えられないという問題意識を共有している [26]。Hu らも、クラスタレベルの説明とインスタンスレベルの説明を概念的に区別し、グループ全体のパターン理解と個別インスタンスの所属理由との間にギャップがあることを指摘する [27]。言い換えれば、個々のサンプルがなぜその予測になったのかを説明する枠組みは整いつつある一方で、あるグループ（クラスタや中間表現の高活性群）全体にどのような意味的性質が共有されているかを直接記述するための枠組みは依然として不十分であり、この集合レベルの説明ギャップが残されている。本研究は、この集合レベル説明ギャップに焦点を当て、特定の概念を持つテキスト集合 A と持たない集合 B の間の意味的な差分を抽出し、このグループレベルの対比的な差分を自然言語ラベルとして記述することを目指す。

2.1.3 反事実の説明

反事実の説明もまた、対比的な要素を持つ XAI 手法として注目を集めてきた。Wachter らは、ある入力 x に対して予測結果 y を所望の値 y' に変えるための距離制約付き最小変化を求めることで、もし年収がこれだけ高ければローンは承認された、といった行動可能な助言を与える枠組みを示した [4]。Dhurandhar らの CEM も、予測を維持するのに十分な特徴と、除去されれば予測が変わる特徴を同時に同定することで、「なぜこのクラスであり、他ではないのか」という対比的説明を与える [5]。一方で、Wachter らは、反事実の説明はモデル内部構造や統計的性質を包括的に明らかにするものではなく、ブラックボックスを開くことなく個々の判断に対して行動可能な情報を与える実務的な第一歩として位置づけている。CEM もまた、個々のインスタンスに対する最小変更に基づく局所的な対比的説明を目的としており、多数のサンプルに共通する概念レベルの差分やグループ全体の振る舞いを直接扱う枠組みではない。

2.2 非教師ありコンセプト発見と命名の課題

従来の特徴量帰属手法がピクセルやトークンといった低レベル特徴の寄与度にとどまり、人間にとって直感的に理解しやすい単位でモデルの振る舞いを説明しにくいという問題意識から、「このレビューは価格に言及している」などの概念に基づいた説明を目指す研究が行われてきた [6]。

コンセプトベース XAI (C-XAI) の代表例である TCAV (Kim et al., 2018) は、概念活性化ベクトルを用いてモデルが特定の概念にどれだけ敏感であるかを、事後説明によって定量化する [6]。TCAV は既存のブラックボックスモデルを固定したまま内部表現空間における「価格」や「サービス」といった概念方向を事後的に学習し、その概念が予測スコアに与える影響を測ることで、説明の単位をピクセルやトークンといった低レベル特徴から、人間が理解しやすい概念へと引き上げる。一方で、TCAV が与えるのはあくまで入出力関

係に基づく感度の解析結果，つまり事後説明であり，モデル内部でどのような機構がどの概念を計算しているのかを直接的に特定するものではない。

2.2.1 人手ラベリングへの依存

事後説明とは別の方向性として，そもそもモデル自体を概念レベルで解釈しやすい構造に設計するアプローチがある．コンセプトボトルネックモデル（Concept Bottleneck Model, CBM）は，入力から概念ベクトルを経由して最終予測を行うモデル構造を直接学習し，中間層の各次元を人間が定義した概念と一対一に対応付ける [41]．これにより，モデルは入力ごとに各概念の有無や強さを中間層で明示的に表現し，最終予測がどの概念にもとづいて行われたのかを，中間表現から直接読み取ることが可能になる．しかし CBM を含む従来の C-XAI は，解釈の基礎となる概念の定義（ラベリング）を人間に依存しているという構造的な問題を抱えてきた [6, 41]．中間層が各概念の有無を正しく表現するように訓練するためには，どのデータにどの概念が含まれているかを示すラベルを大量に用意しなければならない．このプロセスは，高コストな概念キュレーションと呼ばれ，特に医療や科学といった専門知識が必要なドメインでの XAI 導入の最大の障壁となっている．例えばデジタル病理の WSI 診断では，ピクセル単位の手動アノテーションが病理医の大きな負担となることが指摘されている [47]．また，SemEval-2014 のような既存の ABSA ベンチマークにおいてもアスペクトラベルは人手によるアノテーションに依存している [1]．

2.2.2 非教師あり概念抽出とメカニスティック解釈の命名問題

この人手依存の課題を克服するため，非教師ありでモデル内部から概念を抽出する手法の研究が行われてきた．Unsupervised CBM (UCBM) は，CBM のボトルネック構造を引き継ぎつつ，人間による事前定義なしにモデルの内部表現から概念（潜在ベクトル）を自動抽出することを可能にした [16]．また，Compositional Concept Extraction (CCE) は，より構造的な概念の表現を抽出する [39]．しかしこれらの手法が発見する潜在的なベクトル表現に関しても，そのベクトルが人間にとって何を意味するのかという自然言語でのラベリングは，いずれも人手に強く依存している．

さらに，モデル内部の計算過程を直接解析するメカニスティック解釈（Mechanistic Interpretability, MI）分野においても，同様の課題が存在する．Anthropic による Attribution Graphs は，LLM の内部計算プロセスをトレースし，特徴量間の相互作用をグラフとして可視化することで回路を発見する一連のケーススタディを報告している [9]．一方で，同シリーズの手法論をまとめた Circuit Tracing では，グラフのノードとして現れる特徴量が必ずしも自然言語的に意味のある概念とは限らず，各ノードが具体的に何を検出しているかを自然言語で特定するプロセスが自動化されていない [19]．著者ら自身も，解釈を容易にするために関連する意味を持つ特徴量を手動でスーパーノードとしてグループ化しており，この手動ステップが労働集約的であり情報の欠損を引き起こしうると議論している．

このように，C-XAI，非教師ありコンセプト発見，メカニスティック解釈のいずれにおいても，概念や特徴量に対する自然言語での命名は，高コストな人手作業として残されている．

2.2.3 自動概念命名と自動解釈パイプラインの系譜

上記の課題に対し、近年はモデル内部の概念特徴に対して自然言語ラベルを半自動的に付与するパイプラインが多数提案されている。Network Dissection は、CNN の中間ユニットの活性化マップと Broden データセットの概念マスクとの IoU を用いて、あらかじめ定義された概念集合から各ユニットに最も適合するラベルを自動で割り当てる [14]。CLIP-Dissect は、CLIP の画像・テキスト埋め込み空間を利用し、ユニットが強く反応する画像群と多数のテキスト候補との類似度にもとづいて、よりオープンボキャブラリに近い形で命名を行う [15]。Label-free CBM [17] や Discover-then-Name CBM [18] は、タスクに関連する概念バンク自体を GPT 系 LLM や CLIP から自動生成し、発見された潜在ベクトルに対して CLIP 類似度や LLM 出力を用いて名前を付与する枠組みを示している。

言語モデルに対しても、OpenAI による自動解釈パイプライン [37] や Anthropic の Auto-Interpretability 系列 [53] のように、トップ発火トークン列を上位の LLM に入力して説明文を生成し、Simulation Score などの自動指標で説明の妥当性を評価する大規模パイプラインが構築されつつある。これらの手法は、モデル内部への直接アクセスを前提としたパイプラインであるという点で共通している。

このようにモデルの内部表現に対して自然言語ラベルを付与する手法が研究される一方で、アспект付きレビューのような実務的データ上で、既存のラベル体系との整合性を外部ゴールドラベルに対する意味的一致度として評価する枠組みは十分に整っていない。

本研究の主眼は、概念特徴を持つテキスト集合と持たないテキスト集合の差分を入力として LLM に命名を行わせ、外部アспектスキーマとの意味的一致度にもとづいて自動概念命名の達成度を定量的に検証することである。この枠組みにより、中間表現への直接アクセスを前提とする設定で発展してきた発見・命名・内部指標による評価の系譜と、外部アспектスキーマを用いた対比因子ラベル生成タスクの観点を接続する。

2.3 LLM を用いた自動ラベル生成と対比的要約

前節までに見たように、モデルの中間表現への直接アクセスを前提とする系譜では、内部表現から概念を発見し、その解釈や命名までを含む自動化パイプラインが構築されつつある。一方で、本研究が扱うのは、ラベルが付与されていない状態のテキスト集合に対して、集合間の対比的な差分のみを手がかりに LLM でラベルを生成し、外部アспектスキーマとの意味的一致度で評価するという問題設定である。本節では、この問題設定に関係する先行研究として、LLM を用いた自動ラベル生成と対比的要約の系譜を整理し、本研究の位置づけを明確にする。

2.3.1 LLM による自動ラベル生成

大規模言語モデル (LLM) は、その強力な文脈理解能力と自然言語生成能力により、様々なラベリングや要約タスクに応用されている。例えば、Huang と He は、テキストクラスタリングを LLM による分類問題として捉え直し、(i) データセットにもとづいて候補ラベル集合を生成し意味的に近いラベルを統合したうえで、(ii) 各テキストに最も適切なラベルを割り当てる、という 2 段階の枠組みを提案している [31]。このように、既存の LLM を用いた命名の多くは、単一の集合 (クラスタ) を対象に、その集合を代表するラベルを与える設定を扱う。また、アспектベース感情分析 (ABSA) においても、LLM をゼロショット

ト／少数例プロンプト、あるいは微調整で用い、アスペクト項抽出や極性分類など、所与のタスク定義にもとづく予測を行う試みが報告されている [30]。これらは、本研究の概念命名と問題意識を共有しつつも、命名対象が集合内の共通点や所与のラベル集合への対応づけに寄りやすい点に特徴がある。

しかし、本研究が重視するのは、単一集合の要約的命名ではなく、ある概念を持つテキスト集合 A と持たないテキスト集合 B の差分、すなわち集合間の対比的な差分を自然言語ラベルとして記述することである。したがって、命名対象が集合内の共通点ではなく集合間の差分である点に本質的な違いがある。加えて、ABSA における LLM の多くの利用は、アスペクトや極性など、あらかじめ定義されたラベル体系にもとづく予測を主眼とするため [30]、非教師ありの設定で未知概念を自動発見・命名する本研究とはタスク設計が異なる。

2.3.2 対比的要約とテキスト分布差分の記述

本研究のタスク設定に概念的に最も近いのは、自然言語処理 (NLP) 分野における対比的要約 (contrastive summarization) またはグループ差分要約 (group-difference summarization) の系譜である。Ströhle らは、2 つ以上の文書群を比較し、そのうちの 1 つの集合に特有で、かつ関連性の高い差異をハイライトする要約を生成することを目的とする研究動向を整理している [28]。STRUM-LLM は、この枠組みを用いて、2 つの比較対象 (例：製品 A vs 製品 B) の差分を、LLM を用いた多段階パイプラインで属性付きの構造化要約として生成する [29]。また、CELL (Contrastive Explanations for Large Language Models) は、LLM の出力に対する対比的な説明 (なぜその出力が選ばれ、他の出力が選ばれなかったのか) を生成するという点で、本研究と問題意識を共有しているが、単一インスタンスの出力に対する説明に焦点を当てている [7]。

Zhong らは、2 つのテキスト分布の違いを自然言語で説明するタスクを明示的に定式化し、本研究と最も近い技術フレームを与えている [49]。彼らは、バイナリ分類における正例クラスと負例クラスをそれぞれ分布 D_1, D_0 とみなし、 D_1 に特徴的で D_0 には見られない差分を、自然言語仮説 (例：is about sports) として生成する。この枠組みは、データセット解析、ショートカット検出、クラスタラベリングなどに応用されている。評価は、各タスクに対して人手で用意された正例クラスの説明文との類似度 (BERTScore および人手評価) にもとづく。ただし、Zhong らの主目的はテキスト分類・トピックラベリング・データセット解析であり、XAI の観点から、モデルや概念抽出器が持つ概念に外部アスペクトスキーマにもとづく名前をどこまで妥当につけられるかを系統的に検証する枠組みを主眼としてはいない。

2.3.3 本研究の位置づけと新規性

以上を踏まえると、(1) LLM によるクラスタラベリングや ChatABSA は単一集合内の共通テーマ命名や教師あり ABSA の補助に焦点を当てており、(2) 対比的要約や Group-Difference Summarization は集合間の差分を自然言語で要約する枠組みを与えており、(3) Zhong らはテキスト分布差分の自然言語仮説学習という最も近いフレームを提示している、という 3 系統が存在する。しかし、これらはいずれも、XAI の観点から LLM を概念命名モジュールとみなし、ABSA や感情・ゲームレビューといった実務的アスペクトスキーマを外部基準として、LLM がテキスト集合差分から既存アスペクト名をどこまで再発見できるかを体系的に評価することを主目的としていない。

本研究は、Zhong らのテキスト分布差分説明フレームや対比的要約の知見を踏まえ、2つのテキスト集合 A と B の差分から対比因子ラベルを生成し、外部アスペクトスキーマとの意味的一致度で評価するベンチマークを構築する。SemEval-2014 ABSA, Steam Review Aspect Dataset, GoEmotions などのゴールドラベル付きデータセットを用い、アスペクトごとにテキスト集合 A/B を定義する。そのうえで、LLM に集合差分のみを提示し、生成された対比因子ラベルと正解アスペクト名の意味的一致度（SBERT 類似度, LLM 評価など）を測ることで、LLM の概念命名性能を XAI の観点から定量化する。

2.4 本章のまとめと本研究の位置づけ

本章では、事後説明・反事実的説明、概念ベース XAI・非教師ありコンセプト発見・メカニスティック解釈、LLM による自動ラベル生成と対比的要約の三系統の関連研究を概観した。事後説明および反事実的説明は、いずれも単一インスタンスの局所的な挙動に焦点を当てており、モデルが内部にもつ概念構造や集合レベルの差分を直接的に捉えることはできない。一方、C-XAI, 非教師ありコンセプト発見, メカニスティック解釈, 自動命名パイプラインは、内部表現へのアクセスを前提として概念の発見・命名・内部指標による評価という流れを確立しつつあるが、ABSA などの外部アスペクトスキーマに対する概念命名性能を横断的に評価する枠組みは未整備である。さらに、Zhong らの分布差分説明や対比的要約の枠組みは、集合差分を自然言語で要約する強力な技術フレームを提供しているものの、XAI の観点から LLM の概念命名能力を実務的スキーマにもとづいて評価することは主目的としていない。

このギャップを埋める具体的タスクとして、本研究は、概念特徴を持つテキスト集合 A と持たない集合 B の差分から対比因子ラベルを生成し、外部アスペクトスキーマとの意味的一致度を評価する対比因子ラベル生成タスクとベンチマークを第三章で定式化する。

第3章 提案手法

第1章で述べたとおり，本論文の目的は，対比因子ラベル生成タスクを通じて，LLM がテキスト集合差分入力だけから既存のアスペクトスキーマの語彙をどの程度再発見できるかを，実務的データセット上で定量的に評価することである．本章では，この目的を達成するために，LLM を用いて，2つのテキスト集合 A と B の差分から対比因子ラベルを自動生成する手法を提案する．実験では，正解アスペクトラベルにもとづいて A/B を構成し，生成ラベルと外部アスペクトスキーマとの意味的一致度で評価する．本論文では，テキスト集合差分入力 (A, B) から自然言語ラベル L を生成する写像 $(A, B) \mapsto L$ を対比因子ラベル生成タスクと呼び，その出力ラベル L を一貫して対比因子ラベルと呼ぶ．

3.1 対比因子ラベル生成タスクの定式化

本研究が提案する対比因子ラベル生成タスクは，集合間の差分を自然言語ラベルとして要約するタスクを定式化する．学習データセット $\mathcal{D}$ から得られる2つのテキスト集合 A と B が与えられるとき，それらの差分を簡潔な自然言語ラベル L として生成する．以下，数学的定式化では集合 A ，集合 B と表記し，プロンプトや実験手順の記述ではグループ A ，グループ B と表記する．このタスクの目的は，集合 A に含まれるテキスト群の意味的・内容的な特徴のうち，集合 B には含まれない差分を抽出・推論し，それを簡潔な自然言語ラベル L として自動的に生成することである．

タスクの例としてレビューの分類を行う深層学習モデル M を考え，メカニスティック解釈にもとづいて中間層の内部要素 N （または教師なし学習によって抽出された潜在概念ベクトル C ）を取り出した状況を想定する．各レビュー x について，内部要素 N の活性化の大きさを $\text{activation}(x, N)$ とおく．例えば， $\text{activation}(x, N)$ が大きいレビューには *it's a bit expensive.* や *The price is good.* のような価格への言及が多く， $\text{activation}(x, N)$ が小さいレビューには価格以外の内容が多い状況を考える．このとき，集合差分入力 (A, B) に対して，グループ A に特徴的でグループ B には見られない差分を表す対比因子ラベル L として，例えば *mentions of price* のような短い自然言語フレーズが生成されることが望ましい．

$\text{activation}(x, N)$ が大きい上位 k 件のテキスト集合を A （発火群），小さい下位 k 件のテキスト集合を B （非発火群）と定義する（ $k = \text{group_size}$ ）．記法を簡単にするため，以下では内部要素 N の場合で表記するが，同様の定式化は概念ベクトル C にも拡張できる． L は，この差分を要約する自然言語フレーズ（価格に関する言及など）である．

このタスク全体は，集合入力からラベルへの写像

$$(A, B) \mapsto L$$

として表される．以下では，この写像を便宜的に `textContrastiveNaming` と呼ぶ．次節では，この写像を LLM を用いた手続きとして具体化し，(i) グルーピング，(ii) プロンプト設計，(iii) ラベル生成の3段階の処理フローとして記述する．

3.2 LLM による対比的要約の実行

本研究では、定式化された対比因子ラベル生成タスクを、LLM の文脈理解能力と自然言語生成能力を活用して解決する。LLM を、集合 A と B の差分を推論し、ラベルを生成する対比因子ラベル生成器として利用する。

提案手法は、以下の 3 段階の処理フローからなる。

1. データ抽出とグルーピング

解釈対象のニューラルネットワーク M と、内部要素として特定の要素 N を選択する。評価データセット $\mathcal{D}$ の各テキスト x を M に入力し、内部要素 N の活性化値 $\text{activation}(x, N)$ を測定する。測定された活性化値に基づき、ハイパーパラメータ group_size を用いて、活性化値が最も高いテキスト群 A と、活性化値が最も低い（またはランダムな）テキスト群 B を抽出する。すなわち、

$$A = \{x_1, \dots, x_k\}, \quad B = \{x'_1, \dots, x'_k\}, \quad k = \text{group_size}$$

とする。 group_size は、プロンプトのコンテキスト長制限と計算コストのトレードオフを踏まえて決定される。

2. プロンプト設計と差分推論 (Prompt Engineering and Contrast Inference) : 抽出されたテキスト集合 A と B の内容を、LLM の入力プロンプトに組み込む。プロンプトは、LLM に対し、単なる要約ではなく グループ A に特徴的でグループ B には見られない主要な違いを特定し、簡潔に回答するという対比因子ラベル生成タスクとして明確に指示する。特に、本研究で用いるプロンプトは次の要素から構成される。

- **タスク説明**: まず 2 つのデータグループを比較して、グループ A に特徴的でグループ B には見られない表現パターンや内容の特徴を特定してください といった指示文を提示する。
- **Few-shot 例 (オプション)** : Few-shot 設定が有効な場合、`examples_section` に【例題 N 】グループ A : [...] グループ B : [...] 回答: [正解ラベル] という形式の例を挿入する。
- **集合 A のテキスト群**: 【グループ A 】の見出しの下に、各テキストを - [テキスト内容] の形式で最大 group_size 件列挙する。
- **集合 B のテキスト群**: 【グループ B 】の見出しの下に、同様の形式でテキストを列挙する。
- **出力制約**: プロンプト末尾で 英語で短いフレーズとして、グループ A に特徴的でグループ B には見られない主要な違いを簡潔に回答してください と指示し、簡潔な対比因子ラベルの生成を求める。

3. 対比因子ラベルの生成

LLM に対して、推論結果にもとづき、集合 A の意味的特性を簡潔に表現した自然言語ラベル L を生成するよう求める。例えば、集合 A が（価格が高すぎる）といったレビューを含み、集合 B がレビューを含むが価格には言及しない場合、`mentions of price` のようなラベルが得られる可能性がある。

3.3 Few-shot ICL の設計

本研究では，Few-shot インコンテキスト・ラーニング（ICL）を，対比因子ラベル生成の補助的な設定として導入する．具体的には，プロンプトに入出力例を含めることで，出力形式や語彙選択の傾向を誘導することを狙う．Few-shot の有無や例題数は，プロンプト設計上の設定項目として扱う．

Few-shot 設定が有効な場合，タスク説明の直後に `examples_section` を挿入する．例の形式は【例題 N 】グループ A: [...] グループ B: [...] 回答: [正解ラベル] とする．shot 数は 0, 1, 3 で行う。

第4章 評価実験

4.1 実験の目的と概要

本章では、提案手法の評価実験の目的、使用データセット、実験設定、評価指標を述べる。実験結果と考察は第5章で報告する。本実験の目的は、外部ラベルにもとづいて定義した2つのテキスト集合 A/B の差分から、LLM (GPT-4o-mini 等) が対比因子ラベルをどの程度生成できるか、また生成ラベルが人手アノテーションによる正解ラベル（またはその説明文）とどの程度意味的に一致するかを、定量的に評価することである。

提案手法のドメイン汎用性を検証するために、レビュー、感情分類、画像キャプションという多様なドメインに属する4種類のデータセットを用いた。SemEval-2014 ABSA, GoEmotions, Steam Review Aspect Dataset では、データセットに付与されたカテゴリ（アスペクト）ラベルを、LLM が生成する対比因子ラベルの妥当性を評価するための正解として用いた。使用したデータセットの概要を表4.1に示す。

表 4.1: 使用データセットの概要

データセット	ドメイン	特徴
SemEval-2014 ABSA	レビュー	具体的アスペクト (Food, Service 等)
GoEmotions	感情分類	抽象的概念 (28 感情カテゴリ)
Steam Review Aspect Dataset	レビュー	ドメイン固有で抽象度の高いアスペクト (Gameplay 等)
COCO Retrieved Concepts	画像キャプション	視覚的概念記述

本実験は、以下の6つの実験カテゴリで構成された。データセット別比較では、SemEval-2014 ABSA, GoEmotions, Steam Review Aspect Dataset の3データセットを用いて、提案手法の基本性能を評価した。Few-shot 設定による性能比較実験では、0-shot, 1-shot, 3-shot の3つの設定を比較した。グループサイズの影響分析実験では、group_size を 50, 100, 150, 200, 300 の5段階で変化させた。モデル比較実験では、GPT-4o-mini と GPT-5.1 の2モデルを比較した。アスペクト説明文の効果検証実験では、アスペクト説明文の有無による性能差を検証した。COCO Retrieved Concepts 実験では、正解ラベルがない画像キャプションデータセットに対する対比因子ラベル生成タスクを検証した。各実験カテゴリの概要を表4.2に示す。

評価の観点として、以下の3つの指標を用いた（各指標の詳細な定義は4.4節を参照）。有効性の評価には、Sentence-BERT (SBERT) 文埋め込みのコサイン類似度を0.0~1.0に正規化した値（以降、SBERT 類似度）を主要指標として使用し、生成ラベルと正解ラベルの意味的類似度を測定した。汎用性の評価には、複数のドメイン（レビュー、感情分類、画像キャプション）と複数のアスペクトタイプ（具体的アスペクト、抽象的概念）に対する性能を測定した。性能の評価には、BLEU スコアを参考指標として使用し、語彙レベルの一致度を補助的に確認した。また、LLM による意味的類似度評価を補助指標として用い、GPT-4o-mini による5段階評価を実施した。用いた評価指標の概要を表4.3に示す。

表 4.2: 実験カテゴリーの概要

実験カテゴリ	目的・検証内容
データセット別比較	基本性能評価 3 データセット
Few-shot 実験	0/1/3-shot 設定の比較
グループサイズ比較	group_size (50–300) の影響分析
モデル比較	GPT-4o-mini vs GPT-5.1
アспект説明文比較	説明文の有無による性能差
COCO 実験	正解ラベルなしデータセットでの検証

表 4.3: 評価指標の概要

評価指標	役割	位置づけ
SBERT 類似度	意味的類似度測定	主要指標
BLEU	語彙レベル一致度確認	参考指標
LLM 評価	意味的類似度評価 (5 段階)	補助指標

4.2 データセット

本研究では、対比因子ラベル生成の汎用性を検証するため、レビュー (SemEval-2014, Steam)、感情分類 (GoEmotions)、画像キャプション (Retrieved Concepts) という異なるテキストタイプから 4 データセットを用いた。以降の考察でデータセット特性を定量的に参照するため、テキスト統計の概要を表 4.4 に示す (語数は小文字化後の空白分割による)。

表 4.4: テキスト統計の概要 (train/dev/test 合算)

データセット	件数	平均語数	中央語数	最大語数	平均ラベル数	複数ラベル率
GoEmotions	54,263	12.83	12	33	1.18	16.25%
Steam Review Aspect	1,100	244.70	156	1,473	3.27	90.27%
SemEval-2014 restaurant14	4,728	19.41	18	79	1.00	0.00%
SemEval-2014 laptop14	2,966	20.75	18	83	1.00	0.00%

4.2.1 Steam Review Aspect Dataset

Steam Review Aspect Dataset は、Steam ゲームレビューから収集されたテキストデータであり、特定のゲームに関する概念特徴 (アспект) に関する言及を含むデータセットである [11]。本データセットは英語の Steam ゲームレビュー 1,100 件 (学習用 900 件、テスト用 200 件) で構成される。原著者は、データ収集が SRec データベースのスナップショットに基づくことを説明している。本研究では、配布ページから公開データセットを取得して使用した¹。レビューを特徴づける 8 種類の概念特徴 (アспектラベル) が人手でアノテーションされており、Recommended (推奨)、Story (物語)、Gameplay (ゲームプレイ)、

¹配布ページ: <https://srec.ai/blog/steam-review-aspect-dataset> (accessed: 2025-12-13)

Visual (視覚), Audio (聴覚), Technical (技術), Price (価格), Suggestion (提案・要望) からなる。各ラベルは、レビュー中で言及される観点を表す。

- Recommended: 他のユーザに対する推奨・非推奨や、全体としておすすめできるかに関する言及
- Story: 物語, キャラクター, プロット, 世界観などストーリー要素に関する言及
- Gameplay: 操作感, 難易度, ゲームシステム, 戦闘や進行などプレイ体験に関する言及
- Visual: グラフィック, 映像表現, アートスタイルなど視覚要素に関する言及
- Audio: BGM, 効果音, 音声, サウンドデザインなど聴覚要素に関する言及
- Technical: 動作の安定性, 最適化, クラッシュ, バグなど技術的側面に関する言及
- Price: 価格, セール, 値段に対する価値などコスト面に関する言及
- Suggestion: 改善要望, 修正提案, 追加してほしい要素など提案・要望に関する言及

ゲームという特定の製品ドメインに特化しており, 特に Gameplay や Technical といったゲーム固有のメカニクスや技術的側面に関する概念特徴を含む。テストセットにおける概念特徴件数の例として, Gameplay が 154 件, Recommended が 148 件, Story が 89 件である。レビュー長は平均 244.70 語 (中央値 156 語, 最大 1,473 語) であり, 語彙タイプ数は 29,056 語である。また, 1 サンプルあたりの平均ラベル数は 3.27 で, 複数概念特徴を併記するレビューは 90.27% を占める。

実験では, 各概念特徴 (アスペクトラベル) について, そのラベルを含むテキスト群をグループ A, 含まないテキスト群をグループ B として構成した。サンプル抽出 (ランダムサブサンプリング等) と group_size の設定は第 4.3.4 節で述べる。

4.2.2 SemEval-2014 ABSA (Restaurants)

SemEval-2014 ABSA (Restaurants) は, アスペクトベース感情分析 (ABSA) の標準的なベンチマークとして広く使用されるレストランレビューのデータセットである [1]。レストランレビューのテキストを含み, 各文に対してアスペクト (観点) とそれに対する感情極性が人手でアノテーションされている。本研究では主に Food (食べ物), Service (サービス), Price (価格), Atmosphere (雰囲気) の 4 種類のアスペクトを用いる。Food や Price は具体的な名詞や数値に関連する言及が中心となる一方, Atmosphere は広範な文脈や比喩的表現からの推論を必要とし, データセット特性と命名性能の関係を考察する際の比較対象となる。本データセットは 1 文あたり 1 アスペクトを前提としており, restaurant14 は平均 19.41 語, laptop14 は平均 20.75 語と短文である (表 4.4)。

実験では, Restaurant ドメインから Food と Service, Laptop ドメインから Battery と Screen の 4 アスペクトを用い, 各アスペクトについて, そのアスペクトを含むテキスト群をグループ A, 含まないテキスト群をグループ B として構成した。サンプル抽出 (ランダムサブサンプリング等) と group_size の設定は第 4.3.4 節で述べる。

使用したアスペクトの選定理由として, Food は具体的な名詞や数値に関連する言及が中心となる具体的なアスペクトとして, Service, Battery, Screen は製品の属性に関する具体的なアスペクトとして選定した。これにより, 具体的なアスペクトにおける命名性能を評価できるようにした。

4.2.3 GoEmotions

GoEmotions は、細粒度感情分類タスクのために Reddit コメントから収集されたデータセットである [10]. Demszyk らによって構築された総レコード数 63,812 件から成るマルチラベル形式のデータセットであり、28 の感情カテゴリ (27 感情 + neutral) でラベル付けされている。主要なカテゴリには Joy (喜び), Anger (怒り), Admiration (称賛), Neutral (中立) などが含まれる。感情という抽象的概念をテキスト集合差分から推論する必要があるため、具体的な物理的実体を持たない概念の命名精度を検証する目的で用いた。実験では任意の感情アスペクト (例: joy) を指定し、その感情を含むテキスト群 A とその他のアスペクトを含むテキスト群 B を比較する設定とした。平均 12.83 語の短文が中心であり、複数感情ラベルを併記するサンプルは 16.25% である (表 4.4)。

実験では、GoEmotions データセットの全 28 感情カテゴリを対象とし、各カテゴリについて、その感情を含むテキスト群をグループ A 、含まないテキスト群をグループ B として構成した。サンプル抽出 (ランダムサブサンプリング等) と group_size の設定は第 4.3.4 節で述べる。

28 感情カテゴリの選定理由として、感情は物理的な実体を持たない高度に抽象的な概念であり、具体的なアスペクトと比較して命名精度が低下する傾向があるかを検証するために、全カテゴリを対象とした。これにより、抽象的な概念における命名性能を包括的に評価できるようにした。

4.2.4 Retrieved Concepts (COCO Captions)

Retrieved Concepts (COCO Captions) は、画像そのものではなく COCO 由来のキャプション集合のみを用いて、視覚的概念に対応するテキスト集合差分から対比因子ラベルを生成する挙動を補助的に検証するために、画像キャプションデータセット COCO に基づいて構築されたデータセットである [40]. MS-COCO 2017 train split の画像に対して、Unsupervised CBM (UCBM) [16] によって抽出された 300 個の潜在コンセプト埋め込みと、CLIP (ViT-B/32) による画像埋め込みとのコサイン類似度を計算し、各コンセプトについて類似度が高い画像 Top-100 と低い画像 Bottom-100 を取得している。各画像には COCO 由来の人手キャプションが 5 つ付与されており、本研究ではこれらのキャプションのみを集合 A, B の要素として利用する。非教師ありに学習された 300 の潜在コンセプト (concept_0 ~ concept_299) に対し、CLIP 類似度にもとづき取得された Top-100/Bottom-100 画像とそのキャプションからなる。各コンセプトに対して人手の正解ラベル (アスペクト名) は与えられておらず、潜在コンセプトとその Top/Bottom 例のみが提供されるため、正解アスペクト名が与えられない設定において、集合差分から対比因子ラベルを生成する挙動を補助的に検証できる。

実験では、300 コンセプトのうち concept_0, concept_1, concept_2, concept_10, concept_50 の 5 コンセプトを用いた。各コンセプトについて、潜在コンセプト埋め込みと画像埋め込みとの CLIP (ViT-B/32) コサイン類似度に基づき、類似度が高い順に Top-100、低い順に Bottom-100 の画像を選び、それらに付与されたキャプションをグループ A (Top 側)、グループ B (Bottom 側) として用いた。サンプル抽出と group_size の設定は第 4.3.4 節で述べる。

正解ラベルが存在しないため、SBERT 類似度 と BLEU スコアは参考値として記録するにとどめ、主に生成された対比因子ラベルと対応する画像群との整合性に基づく定性的評価を行った。

4.3 実験設定

4.3.1 実験パイプラインの概要

本実験は以下の手順で行う。

1. **データセット読み込み**：各データセットからテキストを読み込む。
2. **グループ A/B 抽出**：各データセットで定義された規則（アスペクトラベル、あるいは Retrieved Concepts における Top/Bottom 構造）に基づき、グループ A（特定概念を含むテキスト群）とグループ B（含まないテキスト群）を抽出する。
3. **プロンプト生成**：グループ A とグループ B のテキストリストをプロンプトに組み込む。Few-shot 例が設定されている場合は、プロンプトに Few-shot 例を挿入する。
4. **LLM による対比因子ラベル生成**：4o-mini 等の LLM にプロンプトを入力し、対比因子ラベルを生成する。
5. **評価**：生成されたラベルと正解ラベルの意味的類似度を SBERT 類似度、BLEU、LLM 評価により測定する。

データセット別比較で対象としたアスペクトは、SemEval-2014 から Food, Service, Battery, Screen の 4 種類、GoEmotions から全 28 感情カテゴリ、Steam から Gameplay, Visual, Story, Audio の 4 種類である。

4.3.2 LLM モデルとパラメータ設定

本実験では、対比因子ラベル生成器として 4o-mini を主要モデルとして用いた。モデル比較実験では、5.1 も使用した。4o-mini を選択した理由は、コスト効率が高く、かつ十分な性能を発揮することが既存研究で確認されているためである。

各実験カテゴリでのモデル選択として、データセット別比較、Few-shot 実験、グループサイズ比較実験では 4o-mini を使用した。アスペクト説明文比較実験では 4o を使用した。モデル比較実験では、4o-mini と 5.1 の 2 モデルを比較した。COCO Retrieved Concepts 実験では、4o-mini を使用した。

温度パラメータ (temperature) は、全ての実験で 0.0 を用いた。この設定により、決定論的な出力が得られ、実験の再現性が確保される。

最大トークン数 (max_tokens) の設定として、データセット別比較では max_tokens = 2000 に設定した。Few-shot 実験、モデル比較実験では max_tokens = 100 に設定した。グループサイズ比較実験、アスペクト説明文比較実験、COCO Retrieved Concepts 実験では max_tokens = 2000 に設定した。

その他の生成パラメータとして、top_p や frequency_penalty はデフォルト値を使用した。

4.3.3 プロンプト設計

プロンプトは第 3 章 3.2 節で述べたテンプレートを用い、タスク説明、オプションの Few-shot 例、グループ A/B のテキスト列挙、および出力制約から構成される。

アスペクト説明文の使用方法として、本研究の「アスペクト説明文比較」では、説明文を生成プロンプトに追加しない。代わりに評価時の参照テキストを、従来のアスペクト名（例：food, story）から、対応するアスペクト説明文へ置換して用いる。生成ラベルが説明的フレーズになりやすい一方で、正解側が単語ラベルであるという粒度差が自動評価に与える影響を確認するため、説明文なし条件（参照：アスペクト名）と説明文あり条件（参照：アスペクト説明文）で、生成ラベルとの意味的類似度（SBERT 類似度, BLEU, LLM 評価）を比較した。

4.3.4 データの前処理と分割方法

テキストの前処理手順として、各データセットからテキストを読み込み、アスペクトラベルに基づいてグループ A とグループ B に分割した。テキストの前処理として、特殊文字の処理や正規化は行わず、データセットの生のテキストをそのまま使用した。

グループ A/B の抽出方法として、各アスペクトについて、そのアスペクトを含むテキスト群をグループ A、含まないテキスト群をグループ B として抽出した。各アスペクトについて、そのアスペクトを含むテキスト群（グループ A）と含まないテキスト群（グループ B）を比較した。COCO Retrieved Concepts 実験では、Top-100 のキャプションをグループ A、Bottom-100 のキャプションをグループ B として抽出した。

グループサイズ（group_size）の設定として、データセット別比較では group_size = 100 を用い、グループサイズ比較実験では group_size を 50, 100, 150, 200, 300 の 5 段階で変化させた。

サンプリングは、各グループの候補集合から group_size 件になるようランダムにサブサンプリングし、候補数が group_size 未満の場合は重複を許して補完した。重み付きサンプリングは使用しなかった。

コンテキスト長制限への対応として、プロンプトに投入するテキスト数は各グループで最大 group_size 件としつつ、コンテキスト長超過を回避するため、必要に応じて group_size 未満に制限した。

4.3.5 Few-shot 例の作成方法

Few-shot 例は、各データセットのアスペクトラベルにもとづき作成した。Few-shot 例は、グループ A とグループ B のテキストリスト（抜粋）と、それに対応する正解ラベルで構成された。

選定基準として、(i) 正解ラベルに対応する手がかりがテキスト上で明示的であり、(ii) 他ラベルの手がかりが相対的に少なく、(iii) グループ A/B の差分から回答ラベルが一意に推測しやすい例を優先した。例えば、SemEval-2014 の Food では (採用例) The sushi was fresh and delicious. のように food への言及が中心の文を用い、(非採用例) Great service and tasty food. のように複数アスペクトが同程度に含まれる文は避けた。同様に、GoEmotions の joy では (採用例) I'm so happy for you! のような明示的表現を用い、皮肉や複数感情が混在する文は避けた。Steam では gameplay に関して (採用例) The gameplay loop is addictive. のようにプレイ体験への言及が中心の文を用い、Story/Visual/Price などが同時に強く現れる文は避けた。Few-shot 例の形式は 【例題 N】グループ A: [...] グループ B: [...] 回答: [正解ラベル] であり、N は例題番号である。

0-shot, 1-shot, 3-shot の違いと設定方法として, 0-shot 設定では Few-shot 例を挿入せず, タスク説明のみを提示した. 1-shot 設定では, 1 つの Few-shot 例を `examples_section` に挿入した. 3-shot 設定では, 3 つの Few-shot 例を `examples_section` に挿入した. Few-shot 実験では, 0-shot, 1-shot, 3-shot の 3 つの設定を比較した.

4.3.6 実験カテゴリの定義

各実験カテゴリのパラメータ設定を表 4.5 に示す.

temperature は全条件で 0.0 とし, top_p や frequency_penalty などその他の生成パラメータはデフォルト値を使用した. LLM 評価は gpt-4o-mini (temperature = 0.0) で実施し, COCO 実験のみ無効とした.

表 4.5: 実験カテゴリ別パラメータ設定 (変動項目のみ)

実験カテゴリ	max_tokens	few_shot	group_size	生成モデル
データセット別比較	2000	0	100	4o-mini
Few-shot 実験	100	0/1/3	100	4o-mini
グループサイズ比較	2000	0	50-300	4o-mini
モデル比較	100	0	100	4o-mini, 5.1
アспект説明文比較	2000	0	100	4o
COCO 実験	2000	0	100	4o-mini

4.3.7 比較手法とベンチマーク

LLM によって生成された対比因子ラベルの品質を, 人手アノテーションされた既存の ABSA ベンチマーク (SemEval-2014 Restaurant/Laptop, Steam レビューなど) の正解ラベルとの意味的類似性と比較することで評価した.

4.4 評価指標

生成された自然言語ラベル L の品質を評価するために, SBERT 類似度, BLEU, および LLM による意味的類似度評価を用いた. SBERT 類似度は主要指標として位置づけられ, 生成ラベルと正解ラベルの意味的類似度を測定した. 本タスクでは, LLM が生成するラベルが食べ物に関する言及のような説明的なフレーズとなるのに対し, 正解ラベルは food のような単一の単語であるため, 語彙レベルの一致度を超えたセマンティックな評価が必要である. BLEU は参考指標として位置づけられ, 語彙レベルの一致度を補助的に確認した. LLM 評価は補助指標として位置づけられ, GPT-4o-mini による 5 段階評価を実施した.

4.4.1 BERT スコア (Sentence-BERT 類似度)

BERT 系モデルにより文を埋め込み表現に変換し, 文間の意味的な近さを類似度として数値化する指標である.

本実験では、Sentence-BERT [43] により生成ラベル L と正解ラベル L_{ref} （アスペクト説明文を用いる条件ではその説明文）を文埋め込みに変換し、コサイン類似度を計算する。実装では、SentenceTransformer (all-MiniLM-L6-v2) の文埋め込みを用い、コサイン類似度 $\cos \in [-1, 1]$ を $\frac{\cos+1}{2} \in [0, 1]$ に正規化した値を BERT スコアとして扱う。ここで L_{ref} は、説明文なし条件では正解アスペクト名、説明文あり条件ではそのアスペクト説明文である。

本指標により、生成ラベルが正解ラベル（またはその説明文）と意味的にどの程度一致しているかを連続値で測り、語彙一致に依存しない有効性評価を行うことを狙う。

値が 1.0 に近いほど意味的に類似していることを示す。

4.4.2 BLEU (Bilingual Evaluation Understudy)

BLEU は、生成文と参照文の間の n-gram の重複にもとづき、語彙レベルの一致度を数値化する指標である [12]。

本実験では、NLTK [44] の `sentence_bleu` により、参照側に正解ラベル（またはその説明文）、候補側に生成ラベルを与えて BLEU を算出し、`SmoothingFunction.method1` を適用した。評価範囲は 0.0 から 1.0 であり、1.0 に近いほど一致度が高いことを示す。

本指標は、語彙レベルの一致度を補助的に確認するために用いた。ただし、本タスクでは正解ラベルが food や price のように 1 語の名詞句で与えられることが多い一方、生成ラベルは説明的フレーズになりやすく、n-gram が成立しにくいいため BLEU が低値になりやすい。したがって、BLEU は参考値として解釈する。

4.4.3 LLM 評価スコア

LLM 評価は、LLM を評価器として用い、参照テキストと候補テキストの意味的類似度を段階評価する指標である。

本実験では、参照側に参照テキスト（説明文なし条件では正解アスペクト名、説明文あり条件ではアスペクト説明文）、GPT 系モデルに 5 段階（1-5）で評価させた。データセット別比較、Few-shot 実験、グループサイズ比較実験、アスペクト説明文比較実験では GPT-4o-mini を用い、temperature = 0.0 に設定した。モデル比較実験では GPT-4o を用い、temperature = 0.0 に設定した。COCO Retrieved Concepts 実験では LLM 評価を無効化した。

本指標により、埋め込み類似度では捉えにくい意味的一致／不一致を補助的に確認し、BERT スコアや BLEU の結果の解釈を支えることを狙う。ただし、単一モデルを評価器として用いる自動評価であるため、評価器バイアスが混入し得る点に留意し、補助指標として解釈する。また、LLM 評価ではスコア (score) に加えて判断理由 (reasoning) も JSON 形式で同時に出力させる。reasoning は、スコアが低くなった要因を定性的に確認し、第 5 章の考察で代表例を参照するために用いる。ただし、単一の LLM を評価器として用いる自動評価であり、LLM 評価自体と同様に補助的な情報として解釈する。

評価プロンプトの設計として、以下のプロンプトを使用した。

参照テキストと候補テキストの意味的類似度を 5 段階（1-5）で評価してください。

参照テキスト: {reference_text}

候補テキスト: {candidate_text}

評価基準:

- 5: 完全に同じ意味
- 4: ほぼ同じ意味（細かい違いのみ）
- 3: 類似しているが一部異なる
- 2: 部分的に類似している
- 1: ほとんど異なる

出力形式（JSON 形式）：

```
{
  "score": 4,
  "normalized_score": 0.8,
  "reasoning": "評価理由を簡潔に説明"
}
```

評価基準（5段階評価の詳細）として、1 から 5 の整数で評価し、5 が最も類似度が高く、1 が最も類似度が低い。5 段階評価（1-5）を $\text{normalized_score} = \frac{\text{score}-1}{4} \in [0, 1]$ に正規化して評価に用いる。

SBERT 類似度 との関係として、LLM 評価スコアは SBERT 類似度 を補完する補助指標として位置づけられ、両指標を併用することで生成ラベルの品質を多角的に評価した。

4.5 統計的分析

追加実験では、条件差がアスペクトに依らず一貫して観測されるかを補足的に確認するため、統計的検定を行った。有意水準は $\alpha = 0.05$ （両側）とした。検定対象は、生成ラベルと参照ラベル（または説明文）との意味的一致を表す主要指標である SBERT 類似度（BERT スコア）とした。

4.5.1 繰り返し測定（ブロック）と多水準比較

Few-shot (0/1/3-shot) および group_size (50/100/150/200/300) の比較では、Steam データセットの 4 アスペクトをブロック（繰り返し測定の単位）とみなし、条件を要因とする Friedman 検定を実施した [55, 58]。補足として条件ペアごとの対応のある Wilcoxon 検定（両側）も算出し [57]、多重比較の補正には Holm 法を用いた [56]（主検定が非有意の場合、事後比較は参考として扱う）。

4.5.2 2条件比較

モデル比較およびアスペクト説明文あり/なしの比較では、Steam データセットの 4 アスペクトをブロックとする対応のある Wilcoxon 検定（両側）を用いた [57]。

第5章 結果と考察

本章では，第4章で述べた (i) データセット別比較，(ii) 入力やプロンプト条件別の実験（Few-shot 設定，グループサイズ，使用モデル，アスペクト説明文の有無），(iii) 外部の正解ラベルを前提としないデータセットを用いた検証，(iv) 補足的な分析（エラー分析，統計的分析）の各実験について，それぞれ結果と考察を述べる．

5.1 データセット別比較

本節では，SemEval-2014，GoEmotions，Steam の3 データセットに対してデータセット別比較を行った．以降では，データセット別の集計結果，主要アスペクト別の結果，全体統計の順に結果を示し，最後にこれらの結果にもとづく考察を述べる．

5.1.1 実験結果

実験設定は第4章の表4.5 データセット別比較に従う．結果を表5.1に示す．各データセットについて，「平均」はデータセット別比較で対象とした全アスペクト（SemEval と Steam は各4，GoEmotions は28）における評価スコアの平均，「最小」「最大」は，それぞれ評価スコアが最小，最大のアスペクトの評価スコアを示している．

表 5.1: データセット別比較：データセット別評価スコア

データセット	SBERT 類似度	BLEU	LLM
SemEval-2014			
平均	0.7481	0.0151	0.5500
最小	0.6898	0.0000	0.4000
最大	0.8008	0.0240	0.6000
GoEmotions			
平均	0.7055	0.0049	0.4714
最小	0.5435	0.0000	0.2000
最大	0.8782	0.0330	0.8000
Steam			
平均	0.5328	0.0000	0.2500
最小	0.5111	0.0000	0.2000
最大	0.5603	0.0000	0.4000

表 5.1 より，SBERT 類似度および LLM スコアの平均は SemEval-2014 が最も高く，次いで GoEmotions，Steam の順に低下した．一方で BLEU は全データセットで低く，特に

Steam では常に 0.0 であった.

アスペクト別の結果（主要なアスペクト）を表 5.2 に示す.

表 5.2: データセット別比較：主要アスペクト別評価スコア

データセット	アスペクト	SBERT 類似度	BLEU	LLM
SemEval-2014	Food	0.7526	0.0240	0.6000
	Service	0.6898	0.0123	0.4000
	Battery	0.7491	0.0240	0.6000
	Screen	0.8008	0.0000	0.6000
GoEmotions	Joy	0.7253	0.0143	0.4000
	Anger	0.7719	0.0000	0.6000
	Disgust	0.8782	0.0000	0.6000
	Embarrassment	0.8441	0.0330	0.6000
Steam	Gameplay	0.5424	0.0000	0.4000
	Visual	0.5111	0.0000	0.2000
	Story	0.5176	0.0000	0.2000
	Audio	0.5603	0.0000	0.2000

表 5.2 より, SemEval-2014 では *Screen* が最も高い SBERT 類似度 (0.8008) を示し, GoEmotions では *Disgust* が最も高い (0.8782). Steam では SBERT 類似度が全体として低い一方, LLM スコアも最大 0.4000 に留まり, 他のアスペクトは 0.2000 に留まった.

全体の統計を表 5.3 に示す.

表 5.3: データセット別比較：全体統計

評価指標	平均	最小	最大
SBERT 類似度	0.6910	0.5111	0.8782
BLEU	0.0055	0.0000	0.0330
LLM	0.4556	0.2000	0.8000

表 5.3 より, SBERT 類似度は 0.5111–0.8782 とばらつきがある一方, BLEU は平均 0.0055 と極めて低い. また, LLM スコアは 0.2000–0.8000 の範囲にあり, 条件によって厳しめの評価になっている.

ここで条件とは, データセット別比較において 1 つのアスペクト (または感情カテゴリ) を指定してグループ *A/B* を構成し, 対比因子ラベルを生成・評価する 1 設定を指す. データセット別比較で扱った 3 データセットとアスペクトの組み合わせによる全 36 条件 (SemEval-2014:4, GoEmotions:28, Steam:4) における SBERT 類似度と LLM 評価の順位は正に相関し, Spearman 順位相関は 0.73, *p* は 0.001 未満であった [54].

5.1.2 考察

データセット別比較の結果から, 対比因子ラベル生成タスクにおいて LLM は一定の性能を示すことが確認できる. 表 5.1 が示すように, データセット別の SBERT 類似度と LLM

スコアの傾向は概ね一致しており、SemEval-2014 と GoEmotions が高く、Steam が低い。

この序列は、データセットの特性の違いとして解釈できる。SemEval-2014 や GoEmotions では、アスペクトや感情カテゴリに対応する語彙や典型表現が比較的一貫しており、グループ A/B の差分が特定の意味領域に集中しやすい。例えば、SemEval-2014 (Restaurant14) の *Food* アスペクトでは、グループ A に「The staff was accomodating , the *T* was absolutely delicious and the place is lovely .」や「Best *T* I have ever eaten .」のような、食事 (*T*) の品質に直接言及する短文が多く含まれる。GoEmotions でも同様に、*Joy* アスペクトでは「I'm so happy this post blew up because this is so true」や「This post made me smile, cute doggo」のように、感情（喜び）を直接表す語彙（happy, smile など）がグループ A に多く現れる。その結果、LLM は差分の中心となる要因を短いラベルとして抽出しやすく、安定した命名につながる。一方で Steam はレビューが長文化しやすく記述が多様で、皮肉や複合評価などのノイズも大きいので、アスペクトがレビューの文脈に依存しやすい。このとき A/B の差分は複数の要素に分散しやすく、単一の要因を短いラベルで表現することが難しくなるため、性能が低下したものと考えられる。この点は、Steam が平均 244.70 語の長文レビューであり、複数アスペクトを併記するサンプルが 90.27% を占めるという観察（表 4.4）と整合し、差分が単一の概念軸として立ち上がりにくい条件では命名が不安定化しやすい可能性を示唆する。

アスペクト別に見た場合も、高スコアになりやすい条件は、語彙の一貫性が高いことや、概念が比較的具体的であることに依存する可能性が示唆される。表 5.2 が示すように、SemEval-2014 と GoEmotions では典型的表現が特に明確な「Screen」や「Disgust」といったアスペクトにおける評価スコアが高い。一方で「Service」や Steam データセットの多くのアスペクトのように、曖昧でノイズが大きい条件では、A/B 差分が単一アスペクトに対応しにくく、性能が低下しやすい。

評価指標間の関係として、BLEU は多くの条件で 0.0 となりやすく、生成ラベルが正解ラベルと語彙的に一致しにくいことを示している。一方で SBERT 類似度は、語彙が一致しなくても意味的に近い表現へ言い換えられているケースを捉えやすい。例えば、GoEmotions の「Anger」アスペクトでは、出力ラベルが「Group A features aggressive language and strong emotional expressions.」のように言い換えられることがある。このとき、「Anger」が出力に含まれず、単語レベルの一致（n-gram 一致）がほぼ生じないため、BLEU は 0.0 となる。一方で、SBERT 類似度は文埋め込みにもとづき意味的近さを評価するため、「怒り」を直接言わずに「攻撃的な言語」「強い感情表現」と説明した出力でも 0.77 程度の高い値を取りうる。このタスクでは、正解ラベルが 1 語の名詞句で与えられることが多い一方、生成ラベルは説明的になりやすいため、n-gram 一致に基づく BLEU では過小評価が起きやすいと解釈できる。

SBERT 類似度と LLM 評価は、スコアの水準は異なるものの、どの条件が相対的に良いかという傾向を概ね共有している。一方で、LLM 評価は単なる意味的近さだけを見ているわけではないと考えられる。生成ラベルの中に書かれた根拠（レビュー中に実際に出現した表現）が、対象概念をどれだけはっきり指しているかまで確認して、保守的に妥当性を判定していると解釈できる。言い換えると、その表現が他の近い概念でも出てしまうなら、根拠として弱いとみなす。例えば、GoEmotions の *Relief* では、出力ラベルは「Group A frequently expresses relief and gratitude, often using I'm glad or thank god.」となった。ここで I'm glad や thank god はレビューに実際に出現した表現と捉えられ、重要な情報源である一方、それらは *Relief* だけでなく *Gratitude* などでも現れうるため、この根拠だけでは *Relief* を十分に特定できず、安堵を正確に表現しているとは言い切れない。その結果、

SBERT 類似度は 0.67 程度と中程度である一方で、LLM 評価は 0.4 に留まったと考えられる。したがって、SBERT 類似度は文章の意味的一致を広く測る指標であるのに対し、LLM 評価は根拠の妥当性も含めて、対比因子ラベルとして使える品質かどうかをより直接に確認する指標として位置付けられる。

5.2 Few-shot 設定による性能比較

5.2.1 実験結果

実験設定として、Steam データセットを用いて、Few-shot 設定を 0-shot, 1-shot, 3-shot として性能差を検証した。実験設定は表 4.5 の Few-shot 実験に従う。Few-shot 別の平均スコアを表 5.4 に、アスペクト別の Few-shot 効果を表 5.5 に示す。

表 5.4: Few-shot 設定による性能比較：平均スコア

Few-shot 設定	SBERT 類似度	BLEU	LLM
0-shot			
平均	0.5526	0.0	0.3000
最小	0.5462	0.0	0.2
最大	0.5596	0.0	0.4
1-shot			
平均	0.6530	0.0	0.3500
最小	0.5111	0.0	0.2
最大	0.8356	0.0	0.8
3-shot			
平均	0.5754	0.0	0.4000
最小	0.5416	0.0	0.2
最大	0.6449	0.0	0.6

表 5.4 より、SBERT 類似度は 1-shot が平均 0.6530 と最も高く、0-shot は 0.5526、3-shot は 0.5754 であった。一方で LLM スコアは 0-shot から 3-shot にかけて増加し、BLEU は全設定で 0.0 であった。

表 5.5: Few-shot 設定による性能比較：アスペクト別 SBERT 類似度

アスペクト	0-shot	1-shot	3-shot
Gameplay	0.5462	0.6802	0.5644
Visual	0.5562	0.5111	0.6449
Story	0.5483	0.8356	0.5416
Audio	0.5596	0.5850	0.5505

表 5.5 より、アスペクト別には 1-shot で *Story* が 0.8356 と大きく上昇する一方、*Visual* では 1-shot が 0.5111 と低下しており、Few-shot の効果は一様ではない。SBERT 類似度

について、Few-shot 設定による差がアスペクトに依らず一貫して生じるかを確認するため、表 5.5 の 4 アスペクトをブロックとする Friedman 検定を実施した [55]。その結果、 $p = 0.4724$ となり 0/1/3-shot 間に有意差は確認されなかった。また、Holm 補正付きの対応のある事後比較 [56] でも、全てのペアで非有意であった。

5.2.2 考察

Few-shot の影響は一樣ではなく、評価指標ごとに異なる形で現れた。このずれは、Few-shot が品質を単調に引き上げるというより、生成ラベルの性質を変化させうることを示している。

1-shot で SBERT 類似度が高くなりやすいことは、例示が出力を正解のアスペクト名に近い語彙に変化させた可能性を示している。Steam の正解ラベルは生成されたラベルと比較して短く、生成は説明的になりやすい。このとき、例示は表現の自由度を狭め、語彙の選択をアスペクト名へ寄せるため、意味的一致度が上がりやすい。例えば、正解ラベルが「story」であるタスクにおいて、0-shot 条件では「グループ A は、個人的な体験や感情に基づく詳細なレビューが多い。」という出力ラベルが生成されたが、別のアスペクトの正解ラベル「Gameplay responsiveness and combat feel」を例示として示した 1-shot 条件では、出力ラベルが「Complex narratives and character-driven experiences」に変化した。一方で 3-shot では、複数例の共通パターンを平均化する形で、より抽象的で説明的な対比表現が生じやすい。例えば、上述のタスクにおいて別のアスペクトの正解ラベル「Gameplay responsiveness and combat feel」「Visual quality and art direction」「Story quality and narrative depth」を例示として示した 3-shot 条件では、出力ラベルが「グループ A は、ゲームの感情的な深さやストーリーの質に焦点を当てているのに対し、グループ B はゲームプレイや技術的な問題に重点を置いている。」であった。この表現は対比としては妥当でも、短いアスペクト名との対応は弱まり、SBERT 類似度が伸びにくくなる。ただし、表 5.5 が示すように、*Story* は 1-shot で大きく上昇する一方、*Visual* は 1-shot で低下し 3-shot で上昇するなど、最適な設定がアスペクトで揃わない。さらに、Friedman 検定で有意差が確認されなかったことは、0/1/3-shot の平均差がアスペクト間で一貫して再現される改善とは言い切れないことを意味する。本節の結果は、Few-shot を増やせば良いという単純な関係ではなく、対象アスペクトと評価軸に応じて適切な例示数が異なる可能性を示唆する。

LLM スコアが 3-shot で最大となったことは、説明としての焦点の合致が改善した可能性を示唆する。3-shot では、単語レベルの一致よりも、グループ差分の要点を一貫した観点で述べる出力が得られやすくなり、対比因子ラベルとしての説明妥当性が高く評価された可能性がある。その結果として、SBERT 類似度が必ずしも上がらないまま、LLM スコアだけが上昇する状況が生じたと考えられる。

以上より、Steam を用いた Few-shot 実験から、例示数の増加が SBERT 類似度を一方向に改善するとは限らず、0/1/3-shot は出力の語彙選択と説明性のバランスを変えることで結果を左右しうることを示唆された。

5.3 グループサイズの影響分析

5.3.1 実験結果

Steam データセットを用いて, group_size (50, 100, 150, 200, 300) による性能差を検証した. 実験設定は表 4.5 のグループサイズ比較に従う. 結果を表 5.6 に示す. Friedman 検定では $p=0.3309$ となり, Holm 補正後の全ペア比較も含め有意差は確認されなかった [55, 56].

表 5.6: グループサイズによる性能比較 (各 group_size での全アспект平均値)

group_size	SBERT 類似度	BLEU	LLM
50	0.5455	0.0	0.3000
100	0.5436	0.0	0.3500
150	0.5321	0.0	0.2500
200	0.5396	0.0	0.3000
300	0.5375	0.0	0.2000

表 5.6 より, SBERT 類似度は 0.5321–0.5455 の範囲に収まり, group_size に対する単調な改善は確認できない. また BLEU は全条件で 0.0 であり, LLM スコアも 0.2000–0.3500 の範囲で大きな差は見られない.

全体の統計を表 5.7 に示す.

表 5.7: グループサイズ比較実験: 全体統計

評価指標	平均	最小	最大
SBERT 類似度	0.5396	0.5019	0.5636
BLEU	0.0000	0.0000	0.0000
LLM	0.2800	0.2000	0.6000

表 5.7 より, 全条件を通した SBERT 類似度の範囲は 0.5019–0.5636 であり, group_size の変更は平均値レベルでは限定的な影響に留まった.

5.3.2 考察

本実験では, group_size を増やしても性能が一方に改善する傾向は確認されず, 入力サンプル数に対して性能は概ね安定していた. このことは, 対比因子ラベル生成の難しさが, 単純に証拠 (テキスト) を増やすことよりも, グループ A/B の差分がどれだけ一つの軸としてまとまっているかに強く依存する可能性を示唆する. Steam レビューは同一アспект内でも観点や言い回しが多様であり, 差分が特定の語彙や表現に集中しにくい. そのため, サンプル数を増やすと代表性は高まる一方で, 差分に直接関係しない周辺話題も同時に増えやすく, LLM が抽出すべき対比の焦点がぼやける (あるいは複数軸に分散する) 可能性がある.

また, LLM は集合差分を一つの短い対比因子ラベルへ圧縮して出力する必要があるため, 入力を増やしても出力が保持できる差分情報は必ずしも増えない. 追加サンプルが既存サ

ンプルに対して冗長であれば利得は小さく、混在要素や例外的記述が増える場合には中心差分の抽出が難しくなり得る。

以上より、本研究の性能検証の観点では、`group_size` を大きくすれば必ず精度が上がるという単純な見通しは支持されない。`group_size` が大きくなるほど、プロンプトのコンテキスト長が増加することから、計算コストとのトレードオフを踏まえつつ、対象アスペクトの多様性に対して十分な代表性を確保できる最小限の `group_size` を選ぶのが合理的である。

5.4 モデル比較実験

5.4.1 実験結果

Steam データセットを用いて、GPT-4o-mini と GPT-5.1 の 2 モデルによる性能差を検証した。実験設定は表 4.5 のモデル比較に従う。モデル別の評価スコアを表 5.8 に、アスペクト別の評価スコアを表 5.9 に示す。対応のある Wilcoxon 検定では $p=0.8750$ （中央値差 $4o-mini-5.1 = 0.0158$ ）となり、統計的には差は確認されなかった [57]。

表 5.8: モデル比較実験：平均スコア

モデル	SBERT 類似度	BLEU	LLM
GPT-4o-mini			
平均	0.5453	0.0	0.3000
最小	0.5214	0.0	0.2
最大	0.5600	0.0	0.4
GPT-5.1			
平均	0.5375	0.0	0.2500
最小	0.5167	0.0	0.2
最大	0.5621	0.0	0.4

表 5.8 より、平均では SBERT 類似度は GPT-4o-mini が 0.5453、GPT-5.1 が 0.5375 であり、GPT-4o-mini が僅かに高かった。LLM スコアも GPT-4o-mini が 0.3000、GPT-5.1 が 0.2500 となった。本条件（0-shot・temperature=0）では、GPT-5.1 が一貫して上回る傾向は確認されなかった。

表 5.9: モデル比較実験：アスペクト別 SBERT 類似度

アスペクト	GPT-4o-mini	GPT-5.1	差 (4o-mini-5.1)
Gameplay	0.5600	0.5423	+0.0177
Visual	0.5425	0.5287	+0.0138
Story	0.5573	0.5167	+0.0406
Audio	0.5214	0.5621	-0.0407

表 5.9 より、*Gameplay*、*Visual*、*Story* では GPT-4o-mini が上回る一方、*Audio* は GPT-5.1 が上回っており、優位性はアスペクトに依存していた。また LLM スコアは、*Gameplay*

では GPT-4o-mini が 0.4, GPT-5.1 が 0.2, *Story* では両モデルが 0.4, *Audio* と *Visual* では両モデルが 0.2 であった。

5.4.2 考察

モデル比較実験は、同一の入力条件に対する LLM の違いによる差を確認するために実施した。0-shot・temperature=0 は、例示による誘導を与えずに決定論的に生成する条件であり、モデルが事前知識と入力集合から直接に差分を抽出して命名する能力がより強く反映されることが考えられる。平均で GPT-4o-mini が僅かに上回り、GPT-5.1 が一貫して優位とは言いがたいという観察は、本条件ではモデル世代差がそのまま性能差として現れない可能性を示唆している。本タスクの成否は、対象データにおける差分のまとまりやすさと、短いラベルに落とし込むという生成制約との整合に左右される面が大きい。Steam レビューは記述が多様で、アスペクト内でも観点が分散しやすいため、差分が単一の概念として回収しにくい場合には、モデル能力の差よりも問題設定側の困難さが支配的になる可能性がある。

また、アスペクトごとに優位なモデルが異なる結果は、性能を単一の平均値だけで議論すると重要な差を見落とし得ることを示している。アスペクトによっては言及が具体的で差分が集中しやすい一方、別のアスペクトでは言及が疎で抽象語彙に寄りやすい。この違いは、集合差分が単一の概念としてまとまるか、あるいは複数軸に分散してしまうかに影響し、命名の難易度をアスペクト単位で変化させると考えられる。したがって、モデル比較の解釈は、アスペクト特性と入力集合の構成を媒介として理解するのが適切だと考えられる。

ただし、本実験の比較には限界がある。第一に、LLM スコアの評価器として gpt-4o-mini を用いているため、モデル間比較に評価器バイアスが混入し得る。第二に、アスペクト数が 4 であり、差があっても安定に検出できない可能性がある。第三に、temperature=0・0-shot は比較としては安定だが、多様な候補生成や再ランキングを前提とする運用条件とは異なる。以上を踏まえると、本節の結論は、本条件に限定した上で、平均レベルの差は大きくない一方で、アスペクト単位では優位性が入れ替わり得る、という整理が妥当だと考えられる。

5.5 アスペクト説明文の効果検証

5.5.1 実験結果

実験設定として、Steam データセットを用いて、アスペクト説明文あり条件と説明文なし条件の性能差を検証した。実験設定は表 4.5 のアスペクト説明文比較に従う。LLM 評価は gpt-4o-mini (temperature = 0.0) で実施した。

説明文の有無による性能差を表 5.10 に、アスペクト別の結果を表 5.11 に示す。対応のある Wilcoxon 検定では $p = 0.3750$ であり、非有意であった [57]。

表 5.10 に示すように、説明文あり条件は説明文なし条件と比べて、SBERT 類似度と LLM スコアが高かった。一方で BLEU は両条件で 0.0 であった。

表 5.11 に示すように、説明文の効果はアスペクトによって異なり、*Audio*、*Gameplay*、*Story* では説明文あり条件の SBERT 類似度が高い一方、*Visual* では低かった。

表 5.10: アスペクト説明文の効果検証：平均スコア

条件	SBERT 類似度	BLEU	LLM
説明文なし			
平均	0.5395	0.0	0.2500
最小	0.5311	0.0	0.2
最大	0.5544	0.0	0.4
説明文あり			
平均	0.5496	0.0	0.3000
最小	0.5186	0.0	0.2
最大	0.5810	0.0	0.4

表 5.11: アスペクト説明文の効果検証：アスペクト別 SBERT 類似度

アスペクト	説明文なし	説明文あり
Gameplay	0.5335	0.5523
Visual	0.5311	0.5186
Story	0.5392	0.5467
Audio	0.5544	0.5810

5.5.2 考察

表 5.10 に示すように、説明文あり条件は全体として改善傾向を示したが、検定結果は非有意であった。説明文の効果がアスペクトで揃わないことから、説明文の付与は常に改善をもたらすとは限らない可能性が示唆される。この違いは、説明文がアスペクト固有の差分への注意を促す可能性がある一方で、説明文の抽象度や粒度によっては注意の焦点が拡散し、アスペクト固有性が弱まる可能性があるためと解釈できる。

評価指標の観点では、BLEU は多くの条件で変化を捉えにくい一方で、SBERT 類似度と LLM スコアは条件差を反映し得る。また、SBERT 類似度が近い場合でも LLM スコアに差が生じることがあり、LLM スコアは意味的近さに加えて、対比因子ラベルとして焦点が合っているか、説明として妥当かといった観点をより保守的に評価している可能性がある。

5.6 COCO Retrieved Concepts 実験

5.6.1 実験結果

4.2 節で述べたように、COCO Retrieved Concepts は正解ラベルを持たないため、UCBM で抽出された潜在概念ベクトルとの類似度が高い Top-100 の画像に付与されているキャプション集合をグループ A、Bottom-100 の画像に付与されているキャプション集合をグループ B として用いた。実験設定は表 4.5 の COCO 実験に従う。

生成された対比因子ラベルと画像との整合性を確認するため、代表例として concept_0, concept_1, concept_2, concept_10, concept_50 における Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつの画像を図 5.1–5.5 に示す。

Group A: Top-100



Group B: Bottom-100



生成された対比因子ラベル: Group A features everyday scenes and objects, while Group B focuses on events and people in formal settings.

図 5.1: concept_0 の代表画像例。Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している

concept_0 において生成された対比因子ラベルは、Group A features everyday scenes and objects, while Group B focuses on events and people in formal settings. であった。画像 A1, A2, A4, A5 は人物が写らず、交通信号、飛行機、消火栓、犬、キーボード、マウスといった物体が中心である。画像 A3 は室内の私的環境で人物と家庭内機器が写る。画像 B1 から B4 では複数の人物が写り、バナーやロゴが背景に含まれ、スーツや制服が写る画像が含まれる。画像 B5 では説明文が付された資料的構成が写る。これらの内容から生成された対比因子ラベルが述べる everyday scenes and objects はグループ A の代表画像の内容と対応し、events and people in formal settings はグループ B の代表画像の内容と対応していると解釈できる。

concept_1 において生成された対比因子ラベルは、Group A focuses on sports and outdoor activities. であった。グループ A では、ゴシック建築の外壁に取り付けられた大きな時計塔、室内に設置された装飾的な時計（カエル像と文字盤が一体）、室内の壁に掛かった大きな丸い掛け時計など、時計が複数枚で中心的に現れている。一方、グループ B ではスーツ姿の大人と幼児がサッカーボールを持って芝生の上に立つ屋外シーン、大きな誕生日ケーキを囲む子どもたち、モーターサイクルの展示ブースでバイクにまたがる女性たち、スマートフォンを掲げる男女のプロモーション写真、椅子に座ったスーツ姿の男性のポートレートなどが写る。これらの内容から、生成された対比因子ラベルが述べる sports and outdoor activities は、グループ A では一部（野球、屋外の時計塔）にのみ当てはまる一方で、グループ B にもサッカー等のスポーツ要素が含まれており、グループ間の差分を一貫して要約できていないと解釈できる。むしろ、グループ A では複数枚で時計（clock）が中心的に現れている点が目立ち、生成ラベルは中心的差分（時計・時間）を取り逃がした可能性が高い。

concept_2 において生成された対比因子ラベルは、Group A features animals and nature scenes prominently. であった。グループ A では、白背景に交通信号のみが写る画像、木製の扉と長いベンチの前に人物が座る白黒写真、草原を走る子馬、牧草地に複数の馬、スケートボードに乗ろうとする人物と人工的な起伏が写るモノクロ画像などが含まれる。一方、グループ B ではバナナとサングラスの静物（テキスト入り）、港に停泊する船と街並み、スーツ姿の人物が演台でスピーチする場面、デザートと調理風景のフォトコラージュ、スーツ姿

Group A: Top-100



Group B: Bottom-100




生成された対比因子ラベル: Group A focuses on sports and outdoor activities.

図 5.2: concept_1 の代表画像例. Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している

Group A: Top-100



Group B: Bottom-100



生成された対比因子ラベル: Group A features animals and nature scenes prominently.


図 5.3: concept_2 の代表画像例. Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している

の人物のポートレート（演説会場のような背景）などが写る。これらの内容から、生成された対比因子ラベルが述べる animals and nature scenes は、グループ A では馬が写る 2 枚に強く当てはまる一方で、交通信号や人物+建物、スケートパークには当てはまりにくく、グループ A 全体の共通性をやや強く一般化していると解釈できる。ただし、グループ B には動物がほとんど見られず、人物ポートレートや食べ物、人工物が中心であるため、「A の方が動物・屋外寄り」という方向性の差分は一定程度捉えている可能性がある。


concept_10 において生成された対比因子ラベルは、Group A features children, animals, and family activities. であった。グループ A では、芝生の上のレジャーシートに座る女性とテディベアやお菓子、ヘルメットをかぶった 2 人の子どもがテディベアを持つ様子、室内で年長の女の子がケーキの載ったトレイを持ち幼い女の子が見つめる場面、芝生の上で幼い子どもが犬のぬいぐるみを持って歩く様子、柵越しに女性が幼児を抱きながら馬にえさをやる場面などが写る。一方、グループ B では空港や滑走路に駐機・走行中の旅客機が多く写り、夜の街路に道路標識が写る画像も含まれる。これらの内容から、生成された対比因子ラベルが述べる children / animals / family activities は、グループ A の代表例に概ね一貫して当てはまると解釈できる。一方でグループ B は飛行機や空港設備、都市インフラが中心であり、子どもや家庭的活動、動物（あるいはぬいぐるみ）に対応する要素はほとんど見られないため、対比軸としても識別的である可能性が高い。

concept_50 において生成された対比因子ラベルは、Group A focuses on electronics and mobile devices. であった。グループ A では、手の中にキーボード付き携帯電話と受話器型ハンドセット、棚の上に携帯端末や PDA 等が多数並ぶ様子、机の上に携帯電話やリモコン、USB モデム等の小型電子機器、手に持たれた携帯電話のクローズアップ、車内のホルダーに固定された携帯電話などが写る。一方、グループ B では窓辺で外を眺める犬、公園のベ

Group A: Top-100



Group B: Bottom-100



生成された対比因子ラベル: Group A features children, animals, and family activities.

図 5.4: concept_10 の代表画像例. Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している

Group A: Top-100



Group B: Bottom-100



生成された対比因子ラベル: Group A focuses on electronics and mobile devices.

図 5.5: concept_50 の代表画像例. Top-100 と Bottom-100 それぞれの先頭から順に 5 件ずつ示している

ンチに座る男女、草原で羊の群れを見つめる犬、石浜に座る犬のポートレート、ベッドやソファの上で犬と横たわる人物などが写る。これらの内容から、生成された対比因子ラベルが述べる electronics and mobile devices は、グループ A の代表例にほぼ一貫して当てはまり、対比因子ラベルが対象カテゴリを直接に要約できている可能性が高い。一方でグループ B は犬や人物、屋外風景が中心であり、電子機器が主被写体として現れることはほとんどないため、グループ間の差分も明確だと解釈できる。

5.6.2 考察

COCO Retrieved Concepts は正解ラベルを持たないため、本実験の考察では、LLM がキャプション集合差分から生成した対比因子ラベルが、どの程度グループ差分を適切に要約できているかをまず確認し、次に、失敗が生じた場合にどのようなずれ方をしたかと、そのずれがどの要因に起因しうるかを整理する。ここでは、代表画像を手で点検することで、生成ラベルの適用度とずれ方を具体例にもとづいて評価する。

整合性が高い例として、concept_0 では、生成ラベルが日常的な物体中心の画像群と、公的なイベント性を伴う人物中心の画像群という差分を与えており、代表例から見ても対比軸が比較的一貫していると解釈できる。同様に concept_10 では子ども・家族的活動が、concept_50 では携帯端末を含むモバイル機器が中心的に現れ、対比因子ラベルが対象の潜在概念によって捉えられている特徴を要約できている可能性が高い。これらの成功例に共通する条件として、(i) 画像側のまとまりが強く、グループ内で中心的対象が揃いやすいこと、(ii) キャプション上でも対象カテゴリに対応する語彙手がかりが継続的に出現しやすい

こと、が考えられる。この場合、LLM は頻出かつ識別的な語彙を軸に、高レベル概念として短く要約する処理が得意になりやすい。

一方で失敗例として、concept_1 では生成ラベルが *sports and outdoor activities* を挙げたが、代表画像を見るとグループ内の中心的まとまりは時計や時間に関する対象であり、生成ラベルは差分の中心を取り逃がしていると解釈できる。このずれ方は、差分抽出がグループ全体の代表性よりも、局所的に目立つ要素や一部サンプルに強く反応した可能性を示唆する。例えば、グループ B 側にもスポーツ的要素が混在している状況では、対比因子ラベルとしての識別性が低下しやすく、さらにグループ A 側の主題である時計関連語彙が十分に差分として際立たなかった場合、LLM がより説明しやすい語彙へ引きずられる可能性がある。同型の兆候として、concept_2 では生成ラベルが動物・自然を強く要約した一方、代表画像では該当するのが一部に限られ、グループ全体の共通性をやや誇張していると解釈できる。これは、識別的な少数要素が存在すると、それをグループ全体の特徴として一般化してしまう傾向を示唆している。

以上より、本設定での対比因子ラベル生成の成否は、LLM の言語化能力だけでなく、Top/Bottom の集合がどれだけ単一概念としてまとまっているか、およびキャプション差分が単一軸に集中しているかというタスク難易度に大きく依存すると考えられる。具体的には、対象の潜在概念の特徴が明確で語彙手がかりが強い場合は成功しやすい一方、混在が大きく差分が分散する場合には、(i) 中心的差分の取り逃がし、(ii) 少数要素への過度な一般化、(iii) 片側だけを説明して対比としての識別性が弱まる、といった失敗が生じやすいと解釈できる。UCBM で抽出される潜在概念は、必ずしも明確に解釈可能な特徴を持つとは限らないことから、対比因子の発見が困難である場合には、そのことを明示的に判定するようにタスクを拡張することが今後の課題として挙げられる。

第6章 まとめ

6.1 結論

本研究は、大規模言語モデル (LLM) を用いて、2 つのテキスト集合 A と B の意味的差分を自然言語ラベルとして記述する対比因子ラベル生成タスクを定式化し、LLM を命名モジュールとして用いた場合の性能を複数データセット上で定量的に評価した。実験では、SemEval, GoEmotions, Steam については人手アスペクトラベルにもとづくテキスト集合、COCO Retrieved Concepts については Top/Bottom 画像群に付与されたキャプション集合から構成したグループ A/B を用いることで、タスク定義における集合 A と B を具体化した。LLM を対比因子ラベル生成器として利用することで、コンセプトベース XAI が抱えてきた発見された内部構造への命名の自動化欠如という課題に対して、一つの実装可能なアプローチを示した。

SemEval-2014, GoEmotions, Steam, COCO Retrieved Concepts という性質の異なる 4 データセットに対する評価の結果、全 36 実験での SBERT 類似度の平均は 0.6980 であった。0-shot・temperature=0 の条件下でも多くの設定で人手ラベルと一定程度の意味的整合が見られた一方で、データセット間 (例: SemEval と Steam) やアスペクト間にはばらつきや低スコアの事例も存在した。一方で、BLEU スコアはほぼ 0 に張り付いており、本タスクでは語彙一致ではなく意味類似度に基づく評価が必要であることが明らかになった。

Few-shot ICL, group_size, モデル種別, アスペクト説明文の有無を変化させた追加実験により、対比因子ラベル生成性能が、データセット設計やプロンプト設計の影響を受ける傾向が示唆された。特に、SemEval のようにアスペクトとテキスト分布の対応が明瞭なデータセットでは相対的に高いスコアが得られた一方、Steam のようにマルチアスペクトでノイズの大きいドメインではスコアが相対的に低くなる傾向が観測された。

COCO Retrieved Concepts 実験では、少数のコンセプトに対するケーススタディとして、LLM がテキスト集合差分からフォーマルイベント、家族活動、電子機器といった視覚概念を指し示すラベルを生成できる例と、キャプションの頻度バイアスに引きずられて本質的な視覚特徴を十分に捉えられない例の両方が確認された。これらの観察から、提案手法が視覚モデルのニューロン解釈に拡張し得る可能性と、同時にテキスト表現に依存する限界があることが示唆された。

以上より、本研究の評価範囲では、集合差分入力にもとづく対比因子ラベルの生成は、データセットやアスペクトにより性能にばらつきがある一方で、一部条件では正解ラベルと意味的に整合する出力が観測された。また、外部スキーマにもとづく定量評価を通じて、性能が低下しやすい条件とその要因が整理された。

6.2 今後の課題

本研究の問題設定は、第 1 章で述べたように、C-XAI やメカニスティック解釈における高コストな概念キュレーションの負担に関わる命名作業について、LLM がテキスト集合差分

入力から既存スキーマの語彙をどの程度再発見できるかを、正解ラベル付きデータセット上で定量的に検証することであった。本章で示した結果は、この目的に対して一定の示唆を与える一方で、依然として解決されていない論点も多い。本節では、これらの未解決点と今後の方向性を整理する。

第一に、抽象的概念やノイズの大きいドメインに対する対比因子ラベル生成の挙動の理解と、必要に応じた性能改善である。Steam レビューや一部の GoEmotions カテゴリでは、グループ A とグループ B の差分が単一アスペクトに集約されず、対比因子ラベルが曖昧になりやすい。こうした設定に対しては、段階的な推論を促すプロンプティングを導入し、LLM に集合差分の解釈プロセスを段階的に明示させることで、抽象概念の命名がどの程度安定化するかを検討する価値がある。また、Buçinca et al. (2024) [8] は、人間の誤解を見越した対比説明が意思決定スキルの向上に寄与することを示しており、この知見を踏まえて本研究で生成した対比因子ラベルが研究者や実務者のモデル理解・診断にどの程度貢献するかを、小規模なユーザスタディ等を通じて評価することも今後の課題である。

第二に、評価指標の高度化である。本研究では SBERT 類似度 と LLM 評価を中心に用いたが、人間評価との整合性が高いとされる BLEURT [32] や BARTScore [33] などの学習ベース指標を導入し、単一指標に依存しない多面的な評価設計へ拡張することが考えられる。特に、SBERT 類似度 が近い設定間での微細な差異や、LLM スコアが粗い離散値に留まる問題に対して、連続値かつ高感度な指標を組み合わせることにより、解釈の精度と安定性を検証しやすくなると期待される。

第三に、視覚概念に対する対比因子ラベルの精緻化である。COCO Retrieved Concepts 実験では、テキストキャプションのみを入力としたため、キャプションの頻度バイアスにより本質的な視覚特徴を取り逃がすケースが観測された。今後は、画像から抽出した物体ラベルやシーン属性、CLIP ベースの画像埋め込みなどを中間表現として併用し、テキストと視覚特徴の双方に整合する対比因子ラベルを生成する枠組みを検討することが望ましい。

第四に、大規模な潜在概念集合への適用と運用上のスケーラビリティである。本研究ではデータセット単位のアスペクトを対象としたが、実際のモデル解釈では多数の潜在概念や特徴量に対してラベルを付与する必要がある。このため、group_size や Few-shot 設定を含むパイプライン全体の計算効率の最適化と、ラベルの一貫性・冗長性を制御するメタレベルの集約手法を設計し、解釈可能性と運用コストのトレードオフを評価することが重要な検討課題となる。

また、UCBM や Attribution Graphs などの手法によって発見された内部構造に対して、内部要素にもとづいて構成した集合 A/B を入力として対比因子ラベルを付与し、専門家が妥当性を評価する枠組みへの接続も残された課題である。本研究で得られた知見を踏まえ、実際の内部表現を対象とした小規模なケーススタディから段階的に検証を進めることが、概念キュレーションの負担軽減という当初の動機に沿った評価につながると考えられる。

最後に、本研究で提案した対比因子ラベル生成タスクは、集合 A と集合 B の差分を、LLM を用いて人間に分かりやすい自然言語ラベルとして自動付与する枠組みである。第 1 章で述べたように、本手法は規制対応や説明責任を直接的に満たすことを目的とするものではなく、既存モデルの内部状態を科学的に理解するための分析的な透明性を補助するモジュールとして位置付けられる。本研究で扱った評価設定と条件の範囲に限れば、この枠組みはモデル内部の構造を把握するうえで一定の手がかりを与えうることが示唆された。今後、ここで示した課題に対する改良と、より現実的な設定での検証を進めることで、XAI 研究および一部の実運用環境において、本手法が潜在概念の解釈を補助するモジュールとしてどの程度有用かをより慎重に評価していくことが今後の課題となる。

謝辞

本研究の実施にあたり，ファルヌシュさんにはCOCO Retrieved Concepts データセットの提供ならびに作成経緯に関するご説明など，多大なご支援をいただいた．本研究の追加実験を進める上で大いに助けられた．ここに深く感謝申し上げる．

付 録 A 実験詳細

A.1 全アスペクトの結果

本章では、紙幅の都合上本文に掲載しなかった全アスペクトの結果を示す。なお, SemEval-2014 および Steam の「全アスペクト」は, 各データセットに定義された全カテゴリではなく, 本論文のデータセット別比較で用いた代表アスペクト集合 (各 4 件) を指す。一方で GoEmotions については, 本実験で扱った全 28 カテゴリを掲載する。

表 A.1: データセット別比較：本実験で扱った全アスペクト別評価スコア

データセット	アスペクト	SBERT 類似度	BLEU	LLM
SemEval-2014	Food	0.7526	0.0240	0.6000
	Service	0.6898	0.0123	0.4000
	Battery	0.7491	0.0240	0.6000
	Screen	0.8008	0.0000	0.6000
GoEmotions	Admiration	0.7297	0.0000	0.4000
	Amusement	0.6826	0.0000	0.4000
	Anger	0.7719	0.0000	0.6000
	Annoyance	0.7455	0.0000	0.4000
	Approval	0.5560	0.0000	0.2000
	Caring	0.7370	0.0000	0.6000
	Confusion	0.5875	0.0000	0.2000
	Curiosity	0.5960	0.0000	0.2000
	Desire	0.7384	0.0000	0.8000
	Disappointment	0.6495	0.0000	0.2000
	Disapproval	0.6275	0.0000	0.6000
	Disgust	0.8782	0.0000	0.6000
	Embarrassment	0.8441	0.0330	0.6000
	Excitement	0.8566	0.0000	0.8000
	Fear	0.7844	0.0000	0.8000
	Gratitude	0.8301	0.0211	0.8000
	Grief	0.7308	0.0000	0.6000
	Joy	0.7253	0.0143	0.4000
	Love	0.6792	0.0143	0.4000
	Nervousness	0.6364	0.0000	0.4000
	Neutral	0.6405	0.0000	0.4000
	Optimism	0.7438	0.0170	0.6000
	Pride	0.5490	0.0000	0.2000
	Realization	0.6669	0.0143	0.4000
	Relief	0.6751	0.0000	0.4000
	Remorse	0.7231	0.0000	0.4000
	Sadness	0.8255	0.0240	0.6000
	Surprise	0.5435	0.0000	0.2000
Steam	Gameplay	0.5424	0.0000	0.4000
	Visual	0.5111	0.0000	0.2000
	Story	0.5176	0.0000	0.2000
	Audio	0.5603	0.0000	0.2000

参考文献

- [1] M. Pontiki, D. Galanis, J. Pavlopoulos, H. Papageorgiou, I. Androutsopoulos, and S. Manandhar: “SemEval-2014 Task 4: Aspect Based Sentiment Analysis,” in *Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014)*, Dublin, Ireland, August 23–24, 2014, pp. 27–35, doi:10.3115/v1/S14-2004.
- [2] M. T. Ribeiro, S. Singh, and C. Guestrin: “Why should I trust you?: Explaining the predictions of any classifier,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, CA, USA, August 13–17, 2016, pp. 1135–1144, doi:10.1145/2939672.2939778.
- [3] S. M. Lundberg and S.-I. Lee: “A unified approach to interpreting model predictions,” in *Advances in Neural Information Processing Systems*, vol. 30, Long Beach, CA, USA, December 4–9, 2017, pp. 4765–4774, arXiv:1705.07874, doi:10.5555/3295222.3295230.
- [4] S. Wachter, B. Mittelstadt, and C. Russell: “Counterfactual explanations without opening the black box: Automated decisions and the GDPR,” *Harvard Journal of Law & Technology*, vol. 31, no. 2, pp. 841–887, 2017.
- [5] A. Dhurandhar, P. Chen, R. Luss, C. Tu, P. Shanmugam, K. Das, Y. Liu, and P. Tambe: “Explanations based on the Missing: Towards Contrastive Explanations with Pertinent Negatives,” in *Advances in Neural Information Processing Systems*, vol. 31, 2018 (NeurIPS 2018), Montréal, Canada, December 3–8, 2018, arXiv:1802.07623.
- [6] B. Kim, M. Wattenberg, J. Gilmer, C. Cai, J. Wexler, F. Viegas, et al.: “Interpretability beyond feature attribution: Quantitative testing with concept activation vectors (TCAV),” in *Proceedings of the 35th International Conference on Machine Learning (ICML 2018)*, Stockholm, Sweden, July 10–15, 2018, pp. 2668–2677, arXiv:1711.11279.
- [7] R. Luss, E. Miehling, and A. Dhurandhar: “CELL your Model: Contrastive Explanations for Large Language Models,” arXiv preprint arXiv:2406.11785, June 2024.
- [8] Z. Buçinca, S. Swaroop, A. E. Paluch, F. Doshi-Velez, and K. Z. Gajos: “Contrastive Explanations That Anticipate Human Misconceptions Can Improve Human Decision-Making Skills,” arXiv preprint arXiv:2410.04253, October 2024.
- [9] Anthropic: “On the Biology of a Large Language Model,” Transformer Circuits, 2025. Available at <https://transformer-circuits.pub/2025/attribution-graphs/biology.html> (accessed: 2025-12-13).
- [10] D. Demszky, D. Movshovitz-Attias, J. Ko, A. Cowen, G. Nemade, and S. Ravi: “GoEmotions: A Dataset of Fine-Grained Emotions,” in *Proceedings of the 58th Annual*

Meeting of the Association for Computational Linguistics (ACL 2020), pp. 4040–4054, 2020.

- [11] S. Khosasi: “Steam review aspect dataset,” 2024. Available at <https://srec.ai/blog/steam-review-aspect-dataset> (accessed: 2025-12-13).
- [12] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu: “BLEU: a Method for Automatic Evaluation of Machine Translation,” in *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL 2002)*, pp. 311–318, 2002.
- [13] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova: “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” arXiv preprint arXiv:1810.04805, 2018.
- [14] D. Bau, B. Zhou, A. Khosla, A. Oliva, and A. Torralba: “Network Dissection: Quantifying Interpretability of Deep Visual Representations,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2017)*, Honolulu, HI, USA, July 2017, pp. 6541–6549, arXiv:1704.05796.
- [15] T. Oikarinen and T.-W. Weng: “CLIP-Dissect: Automatic Description of Neuron Visual Features with Language Models,” arXiv preprint arXiv:2204.10965, 2022.
- [16] S. Schrodi, M. Rückl, T. Wirth, M. Böhm, and D. Rügamer: “Concept Bottleneck Models Without Predefined Concepts,” arXiv preprint arXiv:2407.03921, 2024.
- [17] T. Oikarinen, S. Tripathi, T. M. Mitchell, and D. Alvarez-Melis: “Label-Free Concept Bottleneck Models,” in *Proceedings of the 11th International Conference on Learning Representations (ICLR 2023)*, Kigali, Rwanda, May 2023, arXiv:2304.06129.
- [18] S. Rao, Y. Zhao, M. Sachan, and A. Gupta: “Discover-then-Name: Task-Agnostic Concept Bottlenecks via Automated Concept Discovery,” arXiv preprint arXiv:2407.14499, 2024.
- [19] E. Ameisen, J. Lindsey, A. Pearce, W. Gurnee, N. L. Turner, B. Chen, C. Citro, D. Abrahams, S. Carter, B. Hosmer, J. Marcus, M. Sklar, A. Templeton, T. Bricken, C. McDougall, H. Cunningham, T. Henighan, A. Jermyn, A. Jones, A. Persic, Z. Qi, T. B. Thompson, S. Zimmerman, K. Rivoire, T. Conerly, C. Olah, and J. Batson: “Circuit Tracing: Revealing Computational Graphs in Language Models,” *Transformer Circuits*, 2025. Available at <https://transformer-circuits.pub/2025/attribution-graphs/methods.html> (accessed: 2025-12-13).
- [20] S. Bordt, M. Finck, E. Raidl, and U. von Luxburg: “Post-Hoc Explanations Fail to Achieve their Purpose in Adversarial Contexts,” in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency (FAccT ’22)*, Seoul, Republic of Korea, June 21–24, 2022, pp. 1495–1515, doi:10.1145/3531146.3533153.
- [21] D. Slack, S. Hilgard, E. Jia, S. Singh, and H. Lakkaraju: “Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods,” in *Proceedings of the 2020 AAAI/ACM Conference on AI, Ethics, and Society (AIES 2020)*, New York, NY, USA, February 7–8, 2020, pp. 180–186, arXiv:1911.02508, doi:10.1145/3375627.3375830.

- [22] D. Alvarez-Melis and T. S. Jaakkola: “On the Robustness of Interpretability Methods,” in *Proceedings of the 32nd Conference on Neural Information Processing Systems (NeurIPS 2018) Workshops*, 2018, arXiv:1806.08049.
- [23] M. Mersha, K. Lam, J. Wood, A. AlShami, and J. Kalita: “Explainable AI: A Survey of Needs, Techniques, Applications, and Future Direction,” arXiv preprint arXiv:2409.00265, 2024.
- [24] C. Rudin: “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, vol. 1, no. 5, pp. 206–215, 2019, doi:10.1038/s42256-019-0048-x.
- [25] G. Vilone and L. Longo: “Explainable Artificial Intelligence: a Systematic Review,” arXiv preprint arXiv:2006.00093, 2020, doi:10.48550/arXiv.2006.00093.
- [26] E. Haedecke, M. Akila, and L. von Rueden: “Global Properties from Local Explanations with Concept Explanation Clusters,” in *World Conference on eXplainable Artificial Intelligence (xAI 2025)*, Springer, Cham, 2025, pp. 3–24, doi:10.1007/978-3-031-41510-0_1.
- [27] L. Hu, M. Jiang, J. Dong, X. Liu, and Z. He: “Interpretable Clustering: A Survey,” arXiv preprint arXiv:2409.00743, 2024.
- [28] T. Ströhle, R. Campos, and A. Jatowt: “Contrastive text summarization: a survey,” *International Journal of Data Science and Analytics*, vol. 18, pp. 353–367, 2024, doi:10.1007/s41060-023-00434-4.
- [29] A. Saha, B. P. Majumder, H. Jhamtani, S. Subramanian, S. Sreedhar, S. Chakrabarti, and P. Kankar: “STRUM-LLM: Attributed and Structured Contrastive Summarization for User-Oriented Comparison,” arXiv preprint arXiv:2403.19710, 2024, doi:10.48550/arXiv.2403.19710.
- [30] P. F. Simmering and P. Huoviala: “Large language models for aspect-based sentiment analysis,” arXiv preprint arXiv:2310.18025, 2023, doi:10.48550/arXiv.2310.18025.
- [31] C. Huang and G. He: “Text Clustering as Classification with LLMs,” in *Proceedings of the 2025 Annual International ACM SIGIR Conference on Research and Development in Information Retrieval in the Asia Pacific Region (SIGIR-AP 2025)*, 2025, doi:10.1145/3767695.3769519.
- [32] T. Sellam, D. Das, and A. Parikh: “BLEURT: Learning Robust Metrics for Text Generation,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL 2020)*, pp. 7881–7892, 2020, doi:10.18653/v1/2020.acl-main.704.
- [33] W. Yuan, G. Neubig, and P. Liu: “BARTScore: Evaluating Generated Text as Text Generation,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, pp. 27263–27277, 2021, doi:10.48550/arXiv.2106.11520.
- [34] E. Reiter: “A Structured Review of the Validity of BLEU,” *Computational Linguistics*, vol. 44, no. 3, pp. 393–401, 2018, doi:10.1162/COLI_a_00322.

- [35] A. Holtzman, J. Buys, L. Du, M. Forbes, and Y. Choi: “The Curious Case of Neural Text Degeneration,” in *International Conference on Learning Representations (ICLR)*, 2020, doi:10.48550/arXiv.1904.09751.
- [36] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi: “BERTScore: Evaluating Text Generation with BERT,” arXiv preprint arXiv:1904.09675, 2019, doi:10.48550/arXiv.1904.09675.
- [37] OpenAI: “Language models can explain neurons in language models,” OpenAI Blog, 2023. Available at <https://openai.com/index/language-models-can-explain-neurons-in-language-models/> (accessed: 2025-12-13).
- [38] S. Bills, N. Muennighoff, R. Hoang, N. Mu, et al.: “Automatically Interpreting Millions of Features in Large Language Models,” arXiv preprint arXiv:2310.13052, 2023.
- [39] A. Stein, A. Naik, Y. Wu, M. Naik, and E. Wong: “Towards Compositionality in Concept Learning,” in *Proceedings of the International Conference on Machine Learning (ICML)*, 2024, doi:10.48550/arXiv.2406.18534.
- [40] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick: “Microsoft COCO: Common Objects in Context,” in *Proceedings of the 13th European Conference on Computer Vision (ECCV 2014)*, Zurich, Switzerland, September 6–12, 2014, pp. 740–755, arXiv:1405.0312, doi:10.1007/978-3-319-10602-1_48.
- [41] P. W. Koh, T. Nguyen, Y. S. Tang, S. Mussmann, E. Pierson, B. Kim, and P. Liang: “Concept Bottleneck Models,” in *Proceedings of the 37th International Conference on Machine Learning (ICML 2020)*, vol. 119, pp. 5338–5348, 2020, arXiv:2007.04612, doi:10.48550/arXiv.2007.04612.
- [42] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever: “Learning Transferable Visual Models From Natural Language Supervision,” in *Proceedings of the 38th International Conference on Machine Learning (ICML 2021)*, vol. 139, pp. 8748–8763, 2021, arXiv:2103.00020, doi:10.48550/arXiv.2103.00020.
- [43] N. Reimers and I. Gurevych: “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, Hong Kong, China, November 3–7, 2019, pp. 3982–3992, doi:10.18653/v1/D19-1410.
- [44] S. Bird, E. Klein, and E. Loper: *Natural Language Processing with Python: Analyzing Text with the Natural Language Toolkit*, O’Reilly Media, 2009, ISBN:9780596516499. Available at <https://www.nltk.org/book/> (accessed: 2025-12-13).
- [45] C. Patrício, I. Rio-Torto, J. S. Cardoso, L. F. Teixeira, and J. C. Neves: “CBVLM: Training-free explainable concept-based Large Vision Language Models for medical image classification,” arXiv preprint arXiv:2501.12266, 2025,

doi:10.48550/arXiv.2501.12266. (Accepted for publication in *Computers in Biology and Medicine*.)

- [46] Y. Deng, Y. Sun, Y. Zhu, Y. Xu, Q. Yang, S. Zhang, M. Zhu, J. Sun, W. Zhao, X. Zhou, and K. Yuan: “Efforts estimation of doctors annotating medical image,” arXiv preprint arXiv:1901.02355, 2019, doi:10.48550/arXiv.1901.02355.
- [47] T. Nan, S. Zheng, et al.: “Deep learning quantifies pathologists’ visual patterns for whole slide image diagnosis,” *Nature Communications*, vol. 16, 5493, 2025, doi:10.1038/s41467-025-60307-1.
- [48] Y.-M. Tseng, W.-L. Chen, C.-C. Chen, and H.-H. Chen: “Evaluating Large Language Models as Expert Annotators,” arXiv preprint arXiv:2508.07827, 2025. (Accepted to COLM 2025).
- [49] R. Zhong, C. Snell, D. Klein, and J. Steinhardt: “Describing Differences between Text Distributions with Natural Language,” in *Proceedings of the 39th International Conference on Machine Learning (ICML 2022)*, vol. 162, pp. 27099–27116, 2022.
- [50] L. Dunlap, Y. Zhang, X. Wang, R. Zhong, T. Darrell, J. Steinhardt, J. E. Gonzalez, and S. Yeung-Levy: “Describing Differences in Image Sets with Natural Language,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2024)*, Seattle, WA, USA, June 17–21, 2024, pp. 17952–17961, arXiv:2312.02974.
- [51] C. M. Pham, A. Hoyle, S. Sun, P. Resnik, and M. Iyyer: “TopicGPT: A Prompt-based Topic Modeling Framework,” in *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT 2024)*, Mexico City, Mexico, June 16–21, 2024, pp. 2956–2984.
- [52] M. S. Lam, J. Teoh, J. Landay, J. Heer, and M. S. Bernstein: “Concept Induction: Analyzing Unstructured Text with High-Level Concepts Using LLoM,” in *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems (CHI ’24)*, Honolulu, HI, USA, May 11–16, 2024, Art. No. 933, doi:10.1145/3613904.3642830.
- [53] A. Templeton, T. Conerly, J. Marcus, J. Lindsey, T. Bricken, B. Chen, A. Pearce, et al.: “Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet,” *Transformer Circuits Thread*, 2024. Available at <https://transformer-circuits.pub/2024/scaling-monosemanticity/> (accessed: 2025-12-13).
- [54] C. Spearman: “The Proof and Measurement of Association between Two Things,” *The American Journal of Psychology*, vol. 15, no. 1, pp. 72–101, 1904, doi:10.2307/1412159.
- [55] M. Friedman: “The Use of Ranks to Avoid the Assumption of Normality Implicit in the Analysis of Variance,” *Journal of the American Statistical Association*, vol. 32, no. 200, pp. 675–701, 1937, doi:10.1080/01621459.1937.10503522.
- [56] S. Holm: “A Simple Sequentially Rejective Multiple Test Procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.

- [57] F. Wilcoxon: “Individual Comparisons by Ranking Methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.
- [58] J. Demšar: “Statistical Comparisons of Classifiers over Multiple Data Sets,” *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006. Available at <https://www.jmlr.org/papers/v7/demsar06a.html> (accessed: 2025-12-16).
- [59] P. Virtanen et al.: “SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python,” *Nature Methods*, vol. 17, pp. 261–272, 2020, doi:10.1038/s41592-019-0686-2.